

수집 데이터 및 데이터 전처리 보고서 (최종본 · 시각화 통합)

- 기준일: 2026-08-04 KST
- 대상: 12개 보험사 실손의료보험 약관
- 운영 기준선: 조항 s6_pymupdf-1.28.0 + 사람 승인 S7.1 OCR facts
- 핵심 원칙: 원문·좌표를 먼저 보존하고, 불확실한 추출 결과는 추정하지 않으며, 사람 승인 전에는 검색·인용·판정에 사용하지 않는다.
- 이 문서는 01_수집데이터_및_전처리.md 와 시각화 부록 01_부록_전처리_시각화_s7.html 의 내용을 하나로 합쳐 재구성한 최종 제출본이다. 부록의 Plotly 차트는 원본 데이터를 그대로 추출해 정적 이미지로 다시 그렸다.

0. 한눈에 보는 결과

이 프로젝트의 전처리는 PDF에서 텍스트만 뽑는 작업이 아니다. 사용자의 계약일에 맞는 약관 판본을 고르고, 그 판본에서 조항·별표·표의 근거 위치를 되짚을 수 있게 만드는 데이터 계보 작업이다.

```
공식 공시 사이트 수집 발생 2,121행
└─ SHA-256 고유 원문 1,703개
    └─ 비의료·여행·사업방법서 336개 격리
    └─ 판정 대상 1,367개
        └─ PyMuPDF 페이지·좌표 추출 1,367개 / 실패 0
        └─ s6 조항 구조화 204,098개
            └─ 어려운 표만 MinerU 구조 복원 후보화
                └─ 생산 candidate 4,562개: 전부 serving.citation 차단
                    └─ 사람 승인 850 facts만 S7.1 증분 릴리스
```

운영 릴리스는 다음 두 층을 합친다.

```
s6_pymupdf-1.28.0 조항 정본
+ 사람 승인 S7.1 OCR 표 facts 850건
= r2026-08-04-clause-s7.1-arctic-ko-ocr-approved
```

S7.1은 모든 PDF를 OCR로 다시 읽은 대체판이 아니다. 텍스트·좌표 추출로 충분한 페이지는 s6를 유지하고, 일반 추출이 표의 행·열 관계를 복원하지 못한 일부 페이지만 구조 복원 후보로 보냈다.

1. 수집 대상과 원칙

수집 목표는 "인터넷에 있는 보험 PDF를 많이 모으는 것"이 아니라, 사용자의 가입 시점에 적용된 실손의료보험 약관을 원문 조항까지 연결할 수 있는 판본 원장을 만드는 것이다.

수집 정책	이유
약관을 수집	요약서·사업방법서는 보험금 판정의 조항 근거로 인용할 수 없음
의료 실손만 판정 대상으로 사용	화재·풍수해의 '실손'은 실제 손해 보상 방식이지 실손의료보험이 아님
판매중지 상품과 개정판도 수집	과거 가입자의 계약에는 현재 판매 중인 약관이 아니라 당시 판본이 적용됨
공식 보험사 공시 페이지를 출발점으로 사용	제3자 파일 저장소보다 출처·판매기간·개정 이력을 추적하기 쉬움
robots-WAF를 우회하지 않음	실제 PDF 경로가 금지되거나 확인이 불가능하면 중단
원문 PDF를 Git에 커밋하지 않음	약관 원문은 저작물이며 재배포 대상이 아님

한화손해보험은 robots.txt 의 허용 목록에 실제 PDF 경로가 없어 제외했다. 차단을 우회해 문서를 늘리는 것보다 수집하지 못한 이유를 남기는 쪽을 택했다.

2. 공식 공시 사이트 크롤링

2-1. 수집 수량의 단위와 계보

수집 과정에는 서로 다른 네 가지 수량이 있다. 단위를 붙이지 않고 모두 "문서 수"라고 부르면 중복 제거와 격리 결과를 잘못 해석하게 된다.

시점-단계	단위	수량	의미
2026-08-01 중간 보고	당시 다운로드 기록	1,817건·5.16GB	삼성생명 등이 진행 중이던 역사적 체크포인트. 최종 분모가 아님
수집 완료 원장	SourceOccurrence	2,121행	같은 PDF가 여러 상품·판매기간에 붙은 발생을 각각 보존
수집 완료 파일 감사	물리 파일	2,030개·5.75GB	중복 파일 정리 전 디스크 기준 스냅샷
내용 중복 제거	SHA-256 Artifact	1,703개	내용이 같은 PDF는 한 벌만 보존
비대상 격리	고유 SHA	336개	비의료 실손 159·여행실손 158·사업방법서 19
전처리 입력	고유 SHA	1,367개	s5 페이지·s6 조항·s7 검증의 공통 분모

같은 약관이 여러 상품이나 판매기간에 붙은 것은 오류가 아니다. 파일은 SHA-256 기준 한 벌만 두되, "어느 상품의 어느 기간에 이 약관이 붙었다"는 발생 기록은 지우지 않았다. 이것이 Artifact 와 SourceOccurrence 를 분리한 이유다.

2-2. 보험사별 최종 계보

아래 표는 현행 raw manifest를 수집 발생 / 고유 SHA / 판정 대상 / 격리 로 다시 집계한 값이다.

보험사	발생	고유 원문	판정 대상	격리
DB손해보험	462	258	236	22
흥국화재	228	205	194	11
흥국생명	18	15	15	0
현대해상	337	280	228	52
KB손해보험	120	112	28	84
롯데손해보험	94	92	92	0
메리츠화재	158	157	9	148
동양생명	13	13	13	0
NH농협손해보험	12	12	12	0
NH농협생명	52	52	52	0
삼성화재	406	307	288	19
삼성생명	221	200	200	0
합계	2,121	1,703	1,367	336

기존 문서의 삼성생명 196건은 추출 메타의 미정규화 보험사명 4건을 별도로 센 값이었다. 이 표는 수집 slug 기준으로 4건을 삼성생명에 합쳐 총계가 실제 전처리 분모 1,367과 맞도록 정리했다.

2-3. 범용 파서 하나로 해결하지 않은 이유

보험사 공시 사이트는 목록과 다운로드 방식이 서로 달랐다. 정적 HTML만 읽는 범용 크롤러로는 세션, 암호화 토큰, JavaScript 렌더링, 단계별 상품 선택을 동시에 처리할 수 없었다. 그래서 API-HTML 사이트는 개별 어댑터로, UI 의존 사이트는 공통 브라우저 엔진과 사이트 설정으로 나눴다.

보험사·유형	막힌 지점	실제 해결 방식
삼성화재	file1/2/3 중 어떤 슬롯이 약관인지 표시가 없음	동일 상품의 세 파일 표지·쪽수를 대조해 약관 슬롯을 확정
DB손해보험	코드형 파일명이라 이름만으로 실손 여부 판단 불가	JSON 카탈로그의 상품·문서 유형과 조인
현대해상	목록·상세가 별도 AJAX 호출	두 단계 POST /ajax.xhi 응답과 판매기간을 결합
KB손해보험	한 상품 상세에 개정판이 다수 존재	판매개시일별 파일을 모두 occurrence로 보존
흥국화재	TYPE=filedownX 가 빠지면 1,571바이트 오류 HTML 반환	외부 JavaScript의 다운로드 함수 원문을 확인해 요청 형식 복원
NH농협생명	세션 없이 상세를 열면 PDF 링크가 빈 값	CookieJar로 세션을 먼저 만들고 HTML viewer와 실제 PDF를 구분
동양생명	목록은 GET, 페이지는 POST인 혼합 구조	브라우저 전이를 관찰해 요청 역할을 분리
NH농협손해보험	상품군→구분→상품을 모두 골라야 링크 생성	UI 3단계를 순서대로 선택하고 파일은 동일 세션에서 다운로드
메리츠화재	직접 요청은 WAF 차단, 품 다운로드는 일반 응답 이벤트에 안 잡힘	Playwright expect_download() 로 실제 다운로드 이벤트 수집
롯데손해보험	중간 단계를 건너뛰면 최종 응답이 0바이트	네 단계 호출을 화면 순서대로 수행
흥국생명	메뉴가 렌더 후 나타나고 응답은 EUC-KR-상품명은 이중 인코딩	브라우저 렌더링, 문자셋 교정, POST 인코딩을 함께 적용
삼성생명	숨겨진 통합검색창을 잘못 선택해 전 상품을 순회	실제 #keywordSearch 를 찾아 실손 검색 결과만 수집

코드상 역할은 다음과 같다.

코드	역할
scripts/crawl/sites/*.py	API·HTML 기반 보험사별 카탈로그와 다운로드 어댑터
scripts/crawl/browser_collector.py:68	JavaScript·세션·단계 선택 사이트의 공통 브라우저 엔진과 설정
scripts/crawl/update_all.py:80	현행 삼성화재·DB손해보험 두 API 어댑터의 증분 실행기
scripts/crawl/reconcile_manifest.py:70	디스크 파일과 매니페스트 불일치 복구·감사
scripts/crawl/dedupe_artifacts.py	SHA가 같은 물리 파일을 한 별로 정리하고 occurrence는 유지
scripts/crawl/verify_coverage.py:204	사이트 목록과 수집 원장을 보험사 단위로 재대조

현재 저장소에는 12개사를 한 명령으로 완전히 재수집하는 정보 CLI가 없다. 특히 scripts/crawl/update_all.py 는 두 어댑터만 등록하고, --recheck 는 인자만 있고 실행 로직이 없다. 따라서 이 파일을 전체 크롤링 재현 명령으로 과장하지 않는다.

2-4. 수집 사고와 그 뒤에 추가한 방어

수집 난이도는 사이트별 셀렉터보다 "정상처럼 보이는 실패"를 찾아내는 데 있었다.

사고	겉으로 보인 상태	실측 원인·영향	복구와 재발 방지
매니페스트 유실	PDF 파일은 존재	디스크 full 뒤 PDF는 쓰이고 append만 실패해 388개 중 377개 기록 없음	{sha12}_{원본명} 과 카탈로그를 조인해 377/377 복구. 모르는 URL·날짜는 추정하지 않고 비움
65,536바이트 잘림	%PDF 로 시작해 정상처럼 보임	HTTP 206 Range 한 구간을 전체 PDF처럼 저장, 165개가 0쪽	206 응답을 버리고 200 전체 응답만 채택, 사후 %PDF · %%EOF 전수 검사
동시 프로세스 12개	다운로드가 계속 진행됨	같은 사이트를 중복 수집해 기록 9,574행·실파일 2,260개, 파일 덮어쓰기 발생	실행 lock과 PID 기록, 한 occurrence 처리 후 기록하는 계약 도입
비실손 오분류	파일명에 '실손'이 없음	코드형 파일명 때문에 삼성화재 79·DB 61건을 비실손으로 오탐	카탈로그 조인 전에는 삭제하지 않음. 삼성생명의 실제 비실손 443건만 분리
자연 중복을 오류로 취급	같은 SHA가 여러 번 등장	같은 약관이 여러 상품·판매기간에 붙음	Artifact 한 별 + SourceOccurrence 전부 보존, 당시 1.39GB 절감
URL 기반 커버리지 오탐	매 실행마다 새 누락으로 보임	일부 사이트 URL의 암호화 토큰이 세션마다 바뀜	(정규화 상품명, 판매개시일) 을 비교 키로 사용


2-5. 수집 품질 검증

검증	범위	결과	해석 제한
문서 종류 표본	12개사×6건=72건의 첫 페이지	요약서·사업방법서 오수집 0	표본 검증이며 전수 문서 의미 분류는 별도 수행
PDF 무결성	당시 1,817건 전수	%PDF 시작·%%EOF 꼬리, 잘림 0	현행 온라인 저장기는 %PDF 와 60MB 상한을 검사하고 EOF는 당시 사후 전수 감사였음
사이트 커버리지	URL·카탈로그 대조 가능한 9개사	누락 0	브라우저 수집 3개사는 PDF URL이 없어 화면 결과건수로 대조
브라우저 3개사	삼성생명·메리츠·NH농협손보	화면 223/157/12 대비 수집 221/158/12	삼성생명 차이 2건 중 확인된 1건은 DRM 컨테이너라 우회하지 않았고, 나머지 1건은 원인 미확정
수집 완료 시점 파일 감사	매니페스트 발생행 2,121·물리 PDF 2,030개(5.75GB)	PDF 매직바이트 이상 0·%%EOF 누락 0·정확히 65,536 바이트인 파일 0·매니페스트↔파일 불일치 0	2026-08-01 스냅샷이며 발생행과 파일 수는 서로 다른 단위

사이트 재조회는 외부 상태가 바뀌고 서버 부하를 일으킨다. 큰 변경 뒤에도 한 번에 전 보험사를 조회하지 않고 `python -m scripts.crawl.verify_coverage --only <slug>` 처럼 단일 보험사로 제한한다.

3. 좌표 기반 전처리

3-1. 전체 파이프라인



원본 mermaid 소스는 부록 코드 저장소 §3-1에 있으며, 위 그림은 그 흐름을 그대로 재구성한 것이다.

실제 본선 진입점은 `scripts/extract/run_all.py` 다. 문서 식별 보조기인 `app/outer/outbound/pdf/extractor.py` 는 표지·목차 표본을 읽는 용도이며 전량 페이지·조항 전처리기로 사용하지 않는다.

3-2. 페이지 정보: 텍스트와 좌표를 함께 보존

scripts/extract/to_page_json.py:167 은 PDF 한 건을 페이지 JSON으로 변환한다.

1. PyMuPDF `page.get_text()` 로 읽기순서 본문을 보존한다.
2. 제어문자·공백을 정리하되 복원하지 못한 PUA 문자를 통계로 남긴다.
3. `page.find_tables()` 의 native 표를 보존한다.
4. 단어 bbox와 PDF 벡터선을 사용한 `table_coords` 결과를 별도로 보존한다.
5. 표 추출 실패를 빈 표로 숨기지 않고 `table_extraction_failed` 나 실패 사유로 남긴다.
6. 문서 SHA·보험사·상품명·판매기간·URL을 페이지 산출물에 다시 연결한다.

native 표와 좌표 표를 둘 다 남긴 이유는 어느 한쪽도 전 문서에서 완전하지 않기 때문이다. 흥국화재의 대표 KCD 22행 표에서 native `find_tables()` 는 2행×3열로 붕괴했다. 이 사례와 같은 조판 3표·66레코드 정답셋 전체의 질병명↔코드 짝 정확도는 통합 전 평평한 페이지 텍스트 기준선 0.455, 벡터선·좌표 복원 1.000이었다. 반대로 벡터선이 없는 표와 단단 본문은 좌표 정렬만으로 구분하기 어렵기 때문에 native 결과를 삭제하지 않았다.

3-3. 좌표 표 복원 방식

scripts/extract/table_coords.py:531 은 단어와 선을 다음 순서로 처리한다.

- 페이지의 2단 패널을 먼저 분리해 서로 다른 본문 열이 한 표로 합쳐지는 것을 막는다.
- 가로·세로 벡터선을 이용해 열 경계와 행 묶음을 복원한다.
- 선이 부족한 경우 단어 정렬·간격·열 밀도로 2열·다열 후보를 만든다.
- `scripts/extract/table_signals.py` 의 업무 키워드·금액·비율·문장형 본문 신호로 후보를 판별한다.
- 확실하지 않은 2열짜릿기 는 자동 채택하지 않고 보류 통계에 남긴다.

좌표 방식의 장점은 빠르고 결정적이며 모든 값에 원문 페이지와 bbox를 남길 수 있다는 것이다. 하지만 병합 셀, 페이지를 넘는 부모 헤더, 3열 이상 무테두리 표, 일반 2단 조판과 표의 구분에는 구조적 한계가 있다. 현재 s5의 원시 2열짜릿기 후보 109,421개는 모두 자동 부착이 차단돼 있다. s6의 `tables_withheld_unverified=109,301` 은 fallback 2열 후보 229개를 제외하는 대신 reject된 선 후보 109개를 포함하므로 같은 분모가 아니다. 좌표 표 0건인 보험사도 있어 "전처리 완료=모든 표 복원 완료"라고 주장하지 않는다.

3-4. 조항·부록 구조화

scripts/extract/to_clauses.py:670 은 페이지 정보를 판정·인용 가능한 구조로 바꾼다.

처리	설명
목차 판정	제N조 문자열 비율이 아니라 목차 제목·항목·연속 페이지 구조를 사용
부 경계	보통약관·특별약관·별표·부록의 제목형 단독 줄을 구분
법령 구간	관계법령을 약관 조항과 분리해 잘못된 보험 조항 인용을 막음
조항 경계	제N조 머리말과 참조 꼬리를 구분하고 항 ①, 호 1., . 가. 계층 복원
locator	문서 SHA·쪽·section-ordinal-content hash를 보존
실패 상태	구조가 불명확하면 <code>suspect</code> 또는 <code>no_clause_heads</code> 로 표시

최종 s6 기준은 1,367문서 전량 생성·실패 0이며, `ok` 1,306·`suspect` 52·`no_clause_heads` 9다. 조항 발생은 204,098개이고 전체 분모 기준 인용 가능 조항은 195,630개(95.85%)다. 판정 경로는 구조가 불명확한 문서에서 추측하지 않고 기권해야 한다.

3-5. 단계별 산출물

단계	대표 산출물	역할
수집 원장	data/raw/manifests/*.jsonl	보험사·상품·판매기간·URL·SHA occurrence
페이지 정보	data/extracted/*/s5_pymupdf-1.28.0/*.json	본문·쪽·native 표·좌표 표·정규화 통계
조항 정보	data/structured/*/s6_pymupdf-1.28.0/*.clauses.json	조·항·호·부록·locator·parse status
전처리 manifest	data/manifests/preprocess/manifest_s6.json	1,367 입력·산출물·코드·환경 해시
OCR shadow	data/candidates/s7_selfpay/	자동 승인되지 않은 자기부담금 candidate facts
승인 OCR facts	data/work/s7_1_approved_facts/	사람이 승인한 fact-chunk-occurrence

4. OCR 모델 선정 과정

4-1. 왜 OCR이 필요했나

OCR 대상 페이지에도 native text와 일부 표 객체는 있었다. 문제는 글자를 전혀 읽지 못한 것이 아니라, 다단 헤더·rowspan·colspan·페이지 경계 때문에 "어떤 금액과 비율이 어느 플랜·진료유형·기관에 속하는가"라는 축 관계가 사라진 것이었다. 따라서 OCR의 역할을 전수 문자 인식 이 아니라 고가치 표의 구조를 HTML grid로 다시 제안하는 문서 파서로 한정했다.

모델 후보는 다음 조건으로 먼저 걸렸다.

- 외부 API가 아니라 오프라인 가중치로 재실행할 수 있을 것
- RTX 4070 SUPER 12GB에서 실행 가능할 것
- KCD의 I/1, 0/0 같은 치명 문자 오류를 따로 썰 수 있을 것
- 표의 행·열·병합 셀과 source bbox를 보존할 것
- 평균 점수보다 금액·코드 오결합 0건을 우선할 것

제작사가 공개한 OmniDocBench·KDoc-OCRBench 점수는 평가셋과 조건이 서로 달라 후보 선정에만 사용하고 최종 서열 근거로 사용하지 않았다. 최종 판단은 같은 보험약관 이미지 실측으로 했다.

4-2. 동일 보험약관 5종 실측

환경은 x600 RTX 4070 SUPER 12GB였다. KCD 정답 22행 1쪽과 서로 다른 자기부담금 표 6쪽, 총 7쪽을 사용했다.

모델	KCD 코드 완전	질병명·코드 같은 행	KCD 1쪽 시간	자기부담금 확장	주요 관찰
opendatalab/MinerU2.5-Pro-2605-1.2B	22/22	21/22	30.685초	7/7 HTML 표·평균 29.055초/쪽	bbox-구조 JSON 보존, 비한글 CJK 0, 중복 라인 0%
ATH-MaaS/OvisOCR2	22/22	21/22	74.678초	7/7 HTML 표·평균 73.671초/쪽	페이지당 CJK 8~66자, 중복 라인 33.33~96.04%
PaddlePaddle/PaddleOCR-VL-1.6	0/22	0/22	81.425초(256 토큰)	확대 보류	첫 코드부터 I00→100, 긴 실행은 12GB 근접 점유 후 미완료
zai-org/GLM-OCR	9/22	3/22	14.497초	확대 보류	빠르지만 한글 오독·중간 절단
ONTHEIT/BizOnAI-OCR 4bit	0/22	0/22	21.579초	확대 보류	I00→100, 출력 절단

Paddle NF4 4bit 대조는 계속 VRAM을 약 45.7% 줄였지만 3.4% 느려졌고 핵심 I00→100 오류가 그대로였다. 즉 양자화는 가능했지만 이 실험의 정확도 병목을 해결하지 못했다.

4-3. MinerU를 선택한 이유

MinerU는 외부 벤치마크 1위라서 선택된 것이 아니다. 동일 보험약관에서 다음 조건을 함께 만족한 가장 실용적인 후보였기 때문이다.

1. KCD 코드 묶음 22/22를 유지했다.

2. 자기부담금 6쪽을 포함한 7쪽 모두에서 HTML 표를 만들었다.
3. 병합 셀과 bbox를 구조화 산출물로 남겼다.
4. Ovis보다 약 2.5배 빨랐고 비한글 CJK-중복 라인이 관찰되지 않았다.
5. 약 2.9GB 수준의 peak VRAM으로 비양자화 경로를 12~16GB 장비에서 실행할 수 있었다.

생산에 사용한 모델과 revision은 다음과 같다.

```
model      opendatalab/MinerU2.5-Pro-2605-1.2B
revision   bff20d4ae2bf202df9f45284b4d43681555a97ed
mode       비양자화, 결정적 생성 설정
role       표 구조 candidate 생성기 - 자동 정답 생성기 아님
```

비교 표본은 7쪽으로 작고 모델별 출력 토큰 상한도 같지 않았다. 따라서 "한국어 보험 문서에서 항상 최고"라고 일반화하지 않는다. 별도로 계획했던 48문서 shadow 평가는 manifest는 있으나 최종 `score.json` 과 완료 리포트가 없어 선정 근거로 사용하지 않았다.

5. 선별 OCR 생산과 승인

5-1. 전수 OCR 대신 어려운 페이지만 선별

1. 자기부담금 업무 키워드가 있는 4,538쪽을 후보화했다.
2. 이 중 우선순위 3,000쪽을 렌더링했다.
3. 금액·비율, 복수 측, 표 헤더, 기존 업무 fact 누락 신호로 OCR-hard 1,361쪽만 남겼다.
4. 렌더 PNG의 byte SHA-256이 완전히 같은 경우에만 결과를 공유해 1,361 occurrence를 832개 고유 이미지로 줄였다.
5. 유사 레이아웃이나 같은 보험사라는 이유로 결과를 전파하지 않았다.

이 방식으로 추론 529회를 줄였고, x600 1대와 RunPod 5대의 총 6GPU에서 MinerU 832/832를 완료했다. 가장 늦은 장비 기준 순수 추론 wall time은 128.9분이었다. 원문 PDF와 DB 자격증명은 보내지 않고 SHA 이름의 렌더 이미지와 최소 실행 manifest를 사용했다. 다만 렌더 이미지도 약간 파생물이라는 점을 고려해, 같은 외부 GPU 실험을 반복할 때는 현행 반출 정책을 다시 승인받아야 한다.

5-2. OCR 결과를 업무 fact로 바꾸는 과정

단계	코드	검증 내용
어려운 페이지 선별	<code>scripts/eval/select_s7_ocr_hard.py</code>	업무어·금액/비율·다측 신호와 기존 누락 조건
exact image 중복 제거·배분	<code>scripts/eval/allocate_s7_ocr_dedup6.py</code>	PNG SHA 완전 일치만 alias 허용
모델 실행	<code>scripts/eval/ocr_sota5_runner.py</code>	모델·입력 SHA·환경·실행 결과 기록
결과 병합	<code>scripts/eval/merge_s7_ocr_dedup6.py</code>	입력 이미지 SHA·모델 revision·alias 계보 검사
표 grid 복원	<code>scripts/eval/selfpay_axis_binder.py:145</code>	rowspan/colspan 논리 grid 확장
업무 측 연결	<code>scripts/eval/selfpay_axis_binder.py:242</code>	plan-service-institution-coverage·금액/비율·bbox 연결
candidate 감사	<code>scripts/eval/audit_s7_candidates.py:76</code>	숫자 원문 대조·bbox·중복 ID·S6 비회귀·격리 상태
S7 결합	<code>scripts/extract/build_s7_hybrid.py:156</code>	역사적 <code>is_table</code> 기준 선 grid→native→OCR candidate 순서, OCR은 candidate-only
사람 승인 물질화	<code>scripts/eval/materialize_s7_1_facts.py:76</code>	<code>approve</code> 패턴만 fact·chunk-occurrence로 변환

구축된 S7의 선 표 우선순위는 아직 현행 `attachment_verdict(T9)` 와 통합되지 않았다. 선 후보 813개 중 builder의 역사적 `is_table` 기준은 777개를 `verified`로 보지만 현행 s6 부착 게이트는 704개만 통과시켜 73개 차이가 난다. `accepted clause` 내용 mismatch 0은 확인됐지만, 이것만으로 S7 page mode의 선 표 분류가 현행 안전 게이트와 같다고 주장하지 않는다.

binder는 표 셀의 값을 임의로 채우지 않는다. 페이지 경계, 빈 plan/service, 불완전 bbox, ragged grid, span mismatch, 비한글 CJK, 알려진 OCR 의심어가 있으면 `review_required` 로 내린다. 아무 사유가 없어도 상태는 `shadow_pass` 일 뿐 자동 승인이 아니다.

5-3. candidate와 사람 승인 결과

구분	결과	운영 처리
OCR 생산 대상 문서	601	후보 선별 분모
candidate가 생성된 문서	573	28문서는 candidate 0
candidate facts	4,562	전부 <code>approval=candidate</code>
<code>shadow_pass</code>	1,390(30.47%)	사람 승인 전 차단
<code>review_required</code>	3,172(69.53%)	사유와 함께 검수 큐
자동 serving/citation	0/4,562	누출 0 확인
사람 검수 범위	29패턴·1,066 facts	전량 라벨
승인	24패턴·850 facts	S7.1 검색·인용 가능
수정 필요	5패턴·216 facts	DB-serving-citation 제외

승인 850 facts는 75개 고유 청크와 850 occurrence가 되어 179문서에 연결됐다. 각 occurrence는 문서 SHA, 원문 쪽, 표 bbox, 렌더 이미지 SHA-256을 보유하며 locator 누락은 0이다.

6. 품질 검증과 승격 게이트

검증 층	검사	실측 결과
입력 계보	이미지 SHA·모델 revision-archive-alias 대조	832/832 입력 일치, 예상 밖 stale 1건 quarantine
숫자 환각 방지	OCR 금액·비율 토큰이 같은 페이지 native text에 존재하는지	금액 4,172/4,172 + 비율 4,124/4,124 = 8,296/8,296
grid-근거	bbox 4좌표, rowspan/colspan, ragged-span mismatch	invalid bbox 0, 결함 신호는 review 사유로 기록
accepted 비회귀	S6 accepted clauses와 S7 결합본 비교	204,098개 내용 mismatch 0
결정성	같은 입력으로 S7 재빌드	page+clause 2,734파일 전부 unchanged
manifest	S7 1,367문서·tree digest 재검증	어긋남 0
격리	candidate의 serving/citation·색인 유입	승인 전 0건
사람 승인	29패턴 원문 대조	approve 24·fix 5
검색 비회귀	기존 417질의 top20·리랭크	승인 OCR fact 6질의·23 pair 실제 유입, 기존 gold rank 변화 0

숫자 토큰 8,296/8,296 일치는 "OCR이 새 숫자를 지어내지 않았다"는 검사다. 그 숫자가 올바른 행·헤더에 연결됐다는 precision을 의미하지 않으므로 최종 측 소속은 사람 승인을 요구했다.

S7.1 적용 전후 기존 검색 평가의 Hit@1과 MRR@10은 동일했다. 이는 새 자기부담금 fact의 독립 정답률을 측정한 결과가 아니라, 승인 fact가 검색에 실제 들어오면서 기존 검색 품질을 훼손하지 않았음을 확인한 비회귀 결과다.

7. 전처리 시각화 (원본 데이터로 재작성)

전처리 결과를 숫자 표만으로 판단하지 않기 위해 문서별 페이지·조항 수, 보험사·세대별 분포, `parse_status` 편향, 오류 부담 Pareto, 조항 길이, KCD 언급, 조항 참조 모호성을 시각화했다. 아래 차트는 원본 `01_부록_전처리_시각화_s7.html` (Plotly 대화형 대시보드)에 내장된 데이터를 그대로 추출해 정적 이미지로 재구성한 것이며, 수치는 원본과 동일하다.

7-0. 시점 경고 — 이 절의 s7 수치와 본문 §3-4의 s6/S7.1 수치는 같은 기준이 아니다


시각화 부록은 **s7 재추출 완료본**(생성 2026-08-04 14:49, 추출기 `hybrid-table-v1`, 문서 1,367 · 조항 204,098)을 기준으로 만들어졌고, 이는 이 문서 §3-4가 다루는 **s6 기준 수치**와 시점이 다르다. 예를 들어 §3-4는 s6 기준 인용 가능 조항을 195,630개(95.85%)로 적었지만, 아래 s7 스냅샷은 "인용 모호 조항"을 8,554개로 별도 집계한다. 두 수치를 같은 표에 섞어 쓰지 않는다.

7-1. s7 스냅샷 핵심 지표

지표	값
parse ok	1,306
suspect	52
인용 모호 조항	8,554
번호 못읽은 항	2,414
법령 원문 조항	31,283
KCD 범위 언급	43,154


부록은 2D 임베딩 투영(t-SNE·PCA)을 의도적으로 뺐다고 밝힌다. 중복 조항이 65%에 달해 투영 그림이 왜곡되고 검색 실패 원인을 설명하지 못하기 때문이며, 대신 k-NN 이웃 혼합률과 Recall@k 실패 슬라이스로 봐야 한다고 명시한다.

7-2. 차트 A — 문서별 쪽수 × 조항 수




parse_status (ok/no_clause_heads/suspect)로 색을 나눈 산점도이며, 조항/쪽 비율 0.3-2.0 기준선을 함께 그렸다. 아래쪽 기준선 부근이나 그 아래에 있는 문서는 쪽수 대비 조항 수가 지나치게 적어 구조화 실패가 의심되는 대상이다. 대부분의 ok 문서는 두 기준선 사이에 모여 있고, no_clause_heads (빨강)는 조항 수 0 부근에 집중돼 있다.

7-3. 차트 D-1 — 보험사 × 세대 문서 수 (코퍼스 편중)




13개 보험사 × 6개 세대(1~5세대+unknown) 문서 수 히트맵이다. 코퍼스가 특정 조합에 편중돼 있음이 바로 보인다 — 예를 들어 흥국화재·삼성화재 4세대는 각각 88건인 반면, 1세대 열은 삼성생명 3건을 제외하면 전부 0이다. 이는 실제 판매 이력의 반영일 수도, 수집 커버리지의 공백일 수도 있어 두 가능성을 구분해서 읽어야 한다.

7-4. 차트 D-2 — 보험사 × 세대 parse_status≠ok 비율 (파서 편향)



같은 축에서 값을 불량률(%)로 바꾼 히트맵이다(회색 - 는 해당 조합에 문서가 아예 없는 셀). 파서 편향이 균일하지 않다 — 동양생명 5세대 66.7%, 삼성생명 2세대 63.6%, 흥국생명 4세대 42.9%, 삼성화재 2세대 33.3%가 특히 높다. 다만 이 셀들은 문서 수 자체가 적어(예: D-1에서 확인 가능) 비율만으로 심각도를 판단하지 않고 표본 크기를 함께 봐야 한다.


7-5. Pareto — 오류 부담 상위 40문서



미해결 항(빨강)과 모호 조항(주황)을 문서별로 쌓아 올리고, 누적 비중(초록 선, 우측 축)을 함께 그렸다. 오류가 가장 많은 상위 40개 문서를 다 고쳐도 전체 오류의 24.1%만 해소된다 — 누적선이 완만하게 우상향할 뿐 꺾이지 않는다는 것은 오류가 소수 문서에 집중돼 있지 않고


전체에 평평하게 퍼져 있다는 뜻이며, 소수 문서 수정만으로 품질 문제가 끝나지 않는다.

7-6. 차트 B — 조항 길이 분포 (n=204,098)




로그 스케일 히스토그램이다. 대부분의 조항은 수십~수천 자 사이에 분포하며, 30,000자를 초과하는 조항은 7건(0.00%)뿐이다. 즉 §3-3에서 언급한 "조항 경계 붕괴"(후속 조항·별표가 통째로 붙는 사례)는 예외적 현상이며 전체 분포를 왜곡하지 않는다.

7-7. 차트 E — 약관이 직접 쓴 KCD 범위 (질병 장 × 성격)



22개 질병 장(章)을 exclude(제외)-exception(예외)-mention(단순 언급) 성격으로 나눠 총 43,154건을 집계했다. 5(정신·행동, 9,821건)·14(비뇨생식, 7,921건)·11(소화, 7,267건) 장이 언급 최다이며, 특히 5(정신·행동) 장은 exception(예외) 유형이 5,898건으로 압도적으로 많아 다른 장과 성격이 다르다 — 정신·행동 관련 질환은 "제외"보다 "예외 조건부 보장"으로 다루지는 경우가 많다는 신호다.

7-8. 차트 F — 준용 모호 최다 문서



문서 3d8126b28d97(동양생명)는 조 번호 참조 1,240건 중 948건(76%)이 모호하다 — 색이 1(질은 남색)이면 그 조 번호를 가진 조항이 문서 안에 하나뿐이라 특정 가능하지만, 2 이상 (보라~노랑)이면 같은 번호의 조항이 여러 개 있어 어느 조를 가리키는지 특정할 수 없다. "특정신체부위·질병보장제한부인수특약"과 "약관요약서" 부(部)에서 모호 참조가 가장 많이 발생한다.

7-9. 전처리 산출물 ↔ DB 적재 정합성

부록이 가장 강하게 경고하는 지점: **s7 산출물은 아직 DB에 적재되지 않았다**. 디스크의 204,098개 조항 중 `policy_clause_occurrence` 에 실린 s7 행은 0건이며, 이는 적재 실패가 아니라 "아직 적재하지 않은 상태"다. 현재 실제 검색은 s6 세대로 돌아간다.

단위	전처리 산출(s7)	DB 적재(s7)
조항(수록) <code>policy_clause_occurrence</code>	204,098	0
고유 내용 <code>policy_clause_content</code>	—	64,607
청크 <code>policy_clause_chunk</code>	—	122,772

`index_generation` 별 발생 수: s6 210,733(게이트 값 채워짐, 지금 검색에 실제 쓰이는 세대), s5-mixed 158,186(게이트 비어 있어 검색 차단). 청크 122,772개는 임베딩 모델 `dragonkue/snowflake-arctic-embed-1-v2.0-ko` (d1024, l8192, c448, o80) 기준이며, 게이트가 채워진 s6 계열 활성 행은 190,155건이다. 즉 이 절의 표·그림(전처리 산출)과 실제 서비스 중인 DB 적재본은 서로 다른 세대를 보고 있다는 점을 분리해서 읽어야 한다.

7-10. 행 단위 검증 캡처 (Parquet + Tad)

집계만으로 "몇 건인가"는 답할 수 있어도 "그게 실제로 무엇인가"는 답하지 못하는 다섯 슬라이스를 Tad(DuckDB 기반) 캡처로 별도 확인했다.

뷰	행 수	무엇을 보는가	후속 조치
v1_clause_boundary	7	한 조항에 후속 조항·별표가 통째로 붙은 경계 붕괴 사례	해당 문서의 종료 머리·별표 경계 규칙 보강 후 재추출
v2_page_fallback	438	조항이 아니라 페이지 덩어리로 남은 9개 문서(폰트 디코딩 실패)	CMap 보정·OCR 재처리, 그전까지 인용 불가 격리
v3_reuse	2,962	최대 170개 문서가 동일 해시·문장을 공유하는 재사용 조항	진짜 표준문구면 canonical/occurrence 유지, 아니면 해시 정규화 재계산
v4_para_marker	2,843	짧은 조문 안에서 본항과 내부 열거가 같은 표지(㉓ 등)를 공유	중첩 열거·항 머리 구분 규칙 신설, 회귀 fixture로 고정
v5_pua	366	미해결 PUA 문자(상위 U+F0289-U+F02BA)와 주변 문맥	빈도 높은 PUA→항 기호 매핑 확정 후 재파싱

주의: 이 캡처는 2026-08-03 10:05 판이라 지금(s7) 데이터와 다르다. 확인된 차이는 v1_clause_boundary가 133행 → 7행으로 줄어든 것뿐이며(경계 붕괴 이슈 대부분 해소 추정), v2(438)·v4(2,843)·v5(366)는 행 수가 그대로다. GUI 자동화가 무인 실행에서 불안정해 재캡처는 사람이 확인하며 별도로 진행한다.

8. 임베딩은 어디까지 전처리인가

임베딩은 넓은 ML 파이프라인에서는 전처리에 포함될 수 있지만, 이 프로젝트의 책임 분리에서는 승인된 텍스트 산출물을 검색 벡터로 바꾸는 **후속 색인 단계**로 보는 것이 더 명확하다.

따라서 이 문서가 책임지는 범위는 다음과 같다.

- 조항·표 사실을 검색 가능한 길이의 `chunk` 로 만들기
- 같은 내용을 나타내는 `content_hash` 와 문서별 출현인 `occurrence` 분리
- 문서 SHA·쪽·section·bbox·locator를 잃지 않기
- 미승인 candidate를 임베딩 입력에서 제외하기
- 어느 전처리 release가 어느 벡터 release로 갔는지 계보 남기기

모델 후보 21회 비교, 접두어, 길이 잘림, bootstrap 신뢰구간, 배포 모델 판단은 `05C_사용_LLM_모델.md` §3과 임베딩 모델 선정 브리핑을 단일 정보으로 둔다.

현재 운영 스냅샷은 다음과 같다.

```

model      dragonkue/snowflake-arctic-embed-l-v2.0-ko
dim         1024
max_seq_length 8192
chunk_budget 448
overlap     80
운영 청크   122,772

```

이 모델은 21회 측정에서 다음 검증에 넣을 1순위로 선택돼 현재 릴리스에 사용됐지만 통계적 최종 우승으로 확정된 것은 아니다. s6 코퍼스 재평가·구어체 질의·별도 holdout·비열등성 허용폭이 남아 있고, `config/accepted_extraction.json` 의 모델 revision도 비어 있어 고정이 필요하다.

9. 재현·감사 명령

로컬에서 안전하게 확인 가능한 명령

```
$env:PYTHONIOENCODING = 'utf-8'

# 전처리 대상과 누락 산출물 확인
python -m scripts.extract.run_all --dry-run

# s5+s6 정합 검사기 자체의 변조 탐지와 실제 기준선 검사
python -m scripts.eval.consistency_check --selftest
python -m scripts.eval.consistency_check

# 동결된 s6 입력·산출물·코드·환경 해시
python -m scripts.extract.build_manifest --schema s6 --verify

# S7 결합본과 OCR candidate 격리·숫자·bbox·S6 비회귀
python -m scripts.extract.build_s7_hybrid --verify
python -m scripts.eval.audit_s7_candidates

# 제출 문서 링크
python -m scripts.verify.check_submission_links
```

수집 도구 사용 시 주의

```
# 로컬 매니페스트·중복·분류 dry-run
python -m scripts.crawl.reconcile_manifest --dry-run
python -m scripts.crawl.dedupe_manifest --dry-run
python -m scripts.crawl.dedupe_artifacts --dry-run
python -m scripts.crawl.classify_documents --dry-run

# 외부 사이트 재조회 - 큰 변경 뒤 단일 보험사로만 제한
python -m scripts.crawl.verify_coverage --only <slug>
```

`update_all.py --recheck` 는 현행 구현에서 동작 계약이 완성되지 않았으므로 재현 명령으로 사용하지 않는다. 수집 어댑터에는 고정 fixture 기반 contract test도 부족해, 사이트 개편 대응은 향후 보강 대상이다.

10. 데이터 공개 범위

산출물	위치	외부 공개
활성 릴리스 포인터	<code>config/accepted_extraction.json</code>	가능
확정 문서 원장	<code>config/confirmed_documents.jsonl</code>	메타데이터 검토 후 가능
전처리 manifest	<code>data/manifests/preprocess/manifest_s6.json</code>	가능
승인 OCR facts	<code>data/work/s7_1_approved_facts/</code>	팀 내부
표 후보 registry	<code>config/candidate_fact_sources.json</code>	경로·해시 메타는 가능
약관 PDF	<code>data/raw/insurance_terms/</code>	재배포 금지
약관 본문 파생 JSON	<code>data/extracted/</code> , <code>data/structured/</code>	재배포 금지

11. 남은 한계

- s5 원시 2열짜집기 후보 109,421개는 자동 부착 차단 상태이며, s6 보류 통계 109,301과 분모가 다르다.

- S7 builder의 역사적 선 표 기준과 현행 T9 부착 게이트 사이에 73개 분류 차이가 남아 있다.
- 좌표 표가 0건인 보험사가 있고, 현재 표 정답셋 120쪽도 전체 보험사·조판을 대표하지 않는다.
- MinerU 5종 비교는 7쪽 소표본이고 모델별 토큰 상한이 달라 전 도메인 우위를 주장할 수 없다.
- 48문서 shadow 계획은 최종 score와 종료 리포트가 없어 완료 실험으로 쓰지 않는다.
- 페이지를 넘는 표의 부모 셀 자동 병합은 지원하지 않으며 이런 후보는 `review_required` 로 남는다.
- 사람 검수는 4,562 candidate 전량이 아니라 29패턴·1,066 facts 범위이며, 850 facts만 승인됐다.
- 승인 OCR facts 전용 독립 holdout이 없어 새 fact의 precision/recall은 아직 확정하지 못했다.
- 장해분류표 지급률 8,586 facts와 지연이자표 36 facts는 candidate-only이며 사람 승인 전 판정 근거가 아니다.
- 기계 대조 확정 문서 850건은 사람 최종 서명과 다르다. 엄격 `human_signoff` 모드에서는 승인 문서가 0건이다.
- 임베딩 revision 고정, s6 코퍼스·구어체·holdout 재평가가 남아 있다.
- 위 7절의 차트는 원본 Plotly 대시보드의 데이터를 그대로 사용해 정적으로 재구성했으나, 원본의 hover 툴팁·확대 등 상호작용 기능은 이 문서에서 제공하지 않는다. 상호작용이 필요하다면 `01_부록_전처리_시각화_s7.html` 을 직접 열어야 한다.

참조

- 실손보험 약관 수집 결과 보고 (2026-08-01)
- 사이트 커버리지 대조 결과 (2026-08-01)
- OCR SOTA 5종 벤치마크 계획 (2026-08-03)
- 오프라인 OCR SOTA 5종 x600 실측 (2026-08-03)
- S7 6GPU OCR candidate 완료 보고 (2026-08-04)
- S7.1 사람 승인 OCR 승격 결과 (2026-08-04)
- 데이터 현황 계약 / 모델 평가 계약 / 임베딩 모델 선정 브리핑 (팀 handoff 문서)