

05C. 사용 LLM 모델

발표 보고서 제출 요구 항목 「사용 LLM 모델」의 정본이다. 파인튜닝은 별도 문서 → [05D 파인튜닝 모델 설계.md](#) 기준일 2026-08-04

0. 한 장 요약

슬롯	선택 모델	상태	근거
답변 생성	google/gemma-4-E4B-it-qat-q4_0-gguf (Q4_0 · llama.cpp)	기본 활성화 · ★artifact SHA-라이브 승인 미완료	\$2
약관 임베딩	dragonkue/snowflake-arctic-embed-l-v2.0-ko (1024d)	★운영 인덱스 적용 중 · 선정은 예비 후보 단계	\$3
검색 리랭커	Qwen/Qwen3-Reranker-4B	오프라인 release 완료 · ★실시간 기본 OFF	\$4
저지연 풀백 리랭커	BAAI/bge-reranker-v2-m3	같은 평가셋에서 측정 · 선언만	\$4
선택형 외부 생성	gpt-4o-mini · gemini-2.5-flash	키가 있을 때만. 기본값 아님	\$2-4
OCR / VLM	선별 OCR 파이프라인	★전처리 도구다. 답변 LLM 이 아니다	\$5

★파인튜닝한 자체 모델은 없다. 이번 릴리스의 품질 향상은 ①데이터 정제 ②임베딩 모델 교체 ③리랭커 도입 ④사람 승인 OCR facts 로 얻었다. 발표에서 "파인튜닝 완료"라고 말하지 않는다.

1. 모델을 코드에 흘지 않는다 — `model_registry.yaml`

모델 ID-revision-checksum-검증정보를 소스가 아니라 데이터에 둔다 (REQ-LLM-REG-01 · `tests/test_model_registry.py` 가 강제).

```
profiles:
- profile_id: local_gemma4_e4b
  provider: local
  provider_model_id: gemma-4-e4b
  revision: bb3b92e6f031fa438b409f898dd9f14f499a0cb0
  artifact_sha256: null # ★로컬 GGUF 해시 미측정 → verified=false
  runtime: llama-cpp-python
  quantization: q4_0
  verified_at: null # ★라이브 승인 안 됨
  supported_tasks: [rag_qa, chat]
  max_tested_context: 1024
  memory_peak_mb: null # ★미측정
  tool_call_verified: false

- profile_id: local_qwen35_4b # ★선언된 대체 프로필. 현재 사용 LLM 이 아니다
  provider: local
  provider_model_id: qwen3.5-4b-instruct
  ...
  tool_call_verified: true
```

규칙 세 가지

- latest alias 금지 — 어제 답과 오늘 답이 달라지면 재현이 불가능해진다
- family-only pin 금지 — 반드시 구체 `provider_model_id`
- `artifact_sha256` / `verified_at` / `memory_peak_mb` 가 `null` 이면 「선언됨.미검증」 → 라이브 승인 전까지는 결론론 테스트(Fake)로만 쓴다

★ `null` 을 비워 둔 채 남겨 뒀다. 채워 넣으면 "검증했다"가 되고, 그건 거짓이다.

2. 답변 생성 LLM — Gemma 4 E4B

2-1. 무엇을 어떻게 띄우나

```
scripts/local_model_server.py
repo_id = google/gemma-4-E4B-it-qat-q4_0-gguf
filename = gemma-4-E4B_q4_0-it.gguf
runtime = llama-cpp-python
port = 8002 ← ★앱 개발 서버 8000 과 분리
n_ctx = 1024 (기본값) ← 환경변수 N_CTX 로 조정
인터페이스 = OpenAI 호환 /v1
```

```
LLM_PROVIDER=local
LOCAL_BASE_URL=http://127.0.0.1:8002/v1
LOCAL_MODEL=gemma-4-e4b
LOCAL_API_KEY=not-needed
LLM_CHAT_ENABLED=true
LLM_REQUEST_TIMEOUT_SECONDS=120
LLM_HEALTH_TIMEOUT_SECONDS=3
```

애플리케이션은 SDK 를 직접 부르지 않고 **gateway**(`app/adapters/llm_gateway.py`)를 부른다. 그래서 `.env` 한 줄로 OpenAI-Gemini 구성으로 갈아 끼운다.

⚠ 문서-코드 불일치 1건: `scripts/local_model_server.py:14` 주석은 `N_CTX` 기본을 "4096" 이라 적었는데 실제 코드(:62)는 "1024" 다. 레지스트리의 `max_tested_context: 1024` 와 코드가 맞고 **주석이 틀렸다.**

2-2. 왜 이 모델인가

이유	설명
로컬 우선	약관 원문·OCR 결과·검색 결과를 외부로 보내지 않는다(\$6 참조)
API 키 없이 실행	심사자가 키 없이 그대로 돌릴 수 있어야 한다
OpenAI 호환 gateway	모델 교체가 <code>.env</code> 한 줄
12GB 안에서 상주 가능	공식 Q4 텍스트 가중치 5.15GB — \$6 예산표

2-3. ★생성 LLM 이 하지 않는 일

이 프로젝트에서 생성 모델은 **보장 여부를 결정하지 않는다.**

검색·게이트가 근거 조항을 확정 → 그 근거만 프롬프트에 넣음 → LLM 은 설명만 생성
근거 0건 → ★LLM 을 아예 호출하지 않고 기권

판정은 규칙엔진(`rules-2026.08.02`)과 인용 게이트가 한다. LLM 은 읽기 쉽게 옮겨 적는 역할이다. 이 분리 덕분에 LLM 이 바뀌어도 판정이 바뀌지 않는다.

2-4. 선택형 외부 모델

```
LLM_PROVIDER=openai    OPENAI_MODEL=gpt-4o-mini    OPENAI_API_KEY=...
LLM_PROVIDER=gemini    GEMINI_MODEL=gemini-2.5-flash    GOOGLE_API_KEY=...
```

기본값이 아니다. 도구호출(tool call) 검증이 필요한 에이전트 경로에서만 고려한다 — 로컬 Gemma 프로파일은 `tool_call_verified: false` 이기 때문이다.

2-5. ★검증되지 않은 것 (숨기지 않는다)

항목	상태	영향
GGUF <code>artifact_sha256</code>	미측정	배포본이 평가본과 같은 파일인지 증명 못 함
<code>memory_peak_mb</code>	미측정	12GB 예산표(\$6)는 공개 스펙 기반 추정이다
<code>verified_at</code> (라이브 품질 승인)	null	"이 모델로 답변 품질이 좋다"를 주장할 수 없다
<code>tool_call_verified</code>	false	도구형 에이전트에는 외부 모델이 필요하다
최대 context	1024 까지만 시험	긴 조항은 잘릴 수 있다

3. 임베딩 — Arctic-ko

3-1. 배포 설정

```
model            dragonkue/snowflake-arctic-embed-l-v2.0-ko
dim              1024
max_seq_length   8192
chunk_budget     448    overlap 80
정밀도          float16
```

운영 인덱스 조각 **122,772** (`config/accepted_extraction.json` → `embed_profile`).

3-2. 어떻게 골랐나 — 남의 벤치마크를 쓰지 않았다

★**질의를 지어내지 않았다**. 우리 약관 코퍼스에서 뽑은 실제 문장을 질의로 썼다.

- 측정 **21회** — fp16 17회 + 4bit 4회
- 질의: 제목 검색 145문항 · 뒷부분 검색 **60문항**(다만·단·그러나...) · 면책 표현 16문항
- 짝비교 + 부트스트랩 **2,000회 95% 신뢰구간**

fp16 17회 상위 결과

모델	차원	최대	MRR	R@10	뒷MRR	면책MRR	잘림
Snowflake/snowflake-arctic-embed-l-v2.0	1024	8192	0.557	0.697	0.290	0.288	0.0%
dragonkue/BGE-m3-ko	1024	8192	0.556	0.697	0.271	0.174	0.0%
★ dragonkue/snowflake-arctic-embed-l-v2.0-ko	1024	8192	0.549	0.703	0.317	0.341	0.0%
nlpai-lab/KURE-v1	1024	8192	0.549	0.724	0.276	0.258	0.0%
intfloat/multilingual-e5-large	1024	512	0.542	0.703	0.187	0.246	27.2%
jhgan/ko-sroberta-multitask (옛 배포 설정)	768	128	0.434	0.607	0.133	0.077	83.7%

3-3. ★결정적이었던 것은 순위표가 아니라 잘림

옛 배포 설정 ko-sroberta @ 128토큰 은 조항의 83.7% 가 잘렸다. 그리고 우리가 실제로 검색해야 하는 문장은 조항 뒤쪽에 있다 — "다만 ... 경우에는 보상하지 않습니다" 가 면책의 실체다.

뒷부분 검색 MRR	ko-sroberta@128	0.133	
	Arctic-ko@8192	0.317	(2.4배)
면책 표현 MRR	ko-sroberta@128	0.077	
	Arctic-ko@8192	0.341	(4.4배)

3-4. ★순위표를 그대로 읽으면 안 된다 — 정직하게 남긴 것

짜비고 결과, 상위 그룹은 95% 신뢰구간이 0 을 걸친다.

```
[title] 기준: Snowflake/snowflake-arctic-embed-l-v2.0 (질의 145 · 부트스트랩 2000회)
dragonkue/BGE-m3-ko -0.001 [-0.053, +0.051] 구간이 0 을 걸침
dragonkue/snowflake-arctic-embed-l-v2.0-ko -0.007 [-0.046, +0.031] 구간이 0 을 걸침
nlpai-lab/KURE-v1 -0.008 [-0.057, +0.045] 구간이 0 을 걸침
...
upskyy/kf-deberta-multitask -0.073 [-0.139, -0.008] ★차이 확인
jhgan/ko-sroberta-multitask (max_seq=512) -0.130 [-0.194, -0.068] ★차이 확인
```

★구간이 0 을 걸치면 "차이를 확인하지 못한 것"이지 "같다"가 아니다. 그리고 기준 대비 16개를 비교했으므로 다중비교 보정 없이 단일 비교로 읽으면 안 된다.

→ 그래서 브리핑 §3-3 은 "1위 확정"이 아니라 "예비 후보를 9개로 줄이는 단계" 로 적혀 있다. 아직 남은 것: s6 코퍼스 재평가 · 구어체 질의 · holdout · 비열등성 δ.

3-5. 그런데 왜 지금 이걸 배포했나

시간 제약 때문이다. 재검증 없이 임의로 바꾸지 않는 것이 더 안전하다고 판단했다 — 임베딩 모델을 바꾸면 전량 재색인(6시간)이고, 그 사이 두 벡터 공간이 섞이면 검색이 조용히 망가진다. 그래서 embed_model 을 기본키에 넣어 섞이지 않게 해 두고, 현재 모델을 유지했다.

4. 리랭커 — 5종 실측 후 Qwen3-Reranker-4B

4-1. 평가 입력 (2026-08-04 · S6 delivery)

1차 검색	Arctic-ko dense top20 (같은 문서 안)
원본 청크	145,220
평가 질의	417 (gold 가 top20 에 있는 retrievable 314)
pair	8,273
입력 SHA-256	f9338edaae9a5d7ac8579888aa7ab5f45db4f6bd7926bce94261867025f1ad2f
GPU	NVIDIA RTX 4000 Ada Generation

4-2. 실측 — retrievable 314문항 기준

모델	Hit@1	MRR@10	대체표현 Hit@1	처리량(pair/s)	top20 환산	판정
Qwen/Qwen3-Reranker-4B	84.71%	0.9104	73.47%	11.36	1.76초	★정확도 우선 승자
BAAI/bge-reranker-v2-m3	78.03%	0.8562	50.00%	40.69	0.49초	저지연 폴백
Alibaba-NLP/gte-multilingual-reranker-base	71.02%	0.8040	45.92%	47.27	0.42초	탈락
Qwen/Qwen3-Reranker-0.6B	71.02%	0.8021	33.67%	7.79	2.57초	★탈락 — \$4-4
jinaai/jina-reranker-v2-base-multilingual	66.56%	0.7777	33.67%	356.56	0.06초	초저지연, 품질 탈락
dense Arctic-ko 기준선	64.65%	0.7684	17.35%	—	—	기준선

paired bootstrap 10,000회 (seed 20260804) — 4B vs BGE

전체 Hit@1	+6.69%p	95% CI [+1.59, +11.78]	
전체 MRR	+0.0542	95% CI [+0.0218, +0.0869]	
대체표현 Hit@1	+23.47%p	95% CI [+11.22, +35.71]	← ★여기서 같았다

★「대체표현」이 결정적이었다. 사용자는 약관 문구 그대로 묻지 않는다. "도수치료 되나요" 라고 묻고 약관은 "의사의 지시 없는 물리요법" 이라 적혀 있다. 그 간극에서 4B 가 BGE 보다 23%p 앞섰다.

4-3. 두 지표를 함께 보고한다

retrievable 314문항	Hit@1 84.71%	MRR 0.9104	← 리랭커의 재배치 능력
전체 417문항	Hit@1 63.79%	MRR 0.6855	← 후보 생성·버전 불일치까지 포함한 종단

★하나만 단독으로 보고하지 않는다. 전체가 낮아지는 주원인은 리랭커가 복구할 수 없는 gold 결측(93건은 S5 평가 ID ↔ S6 delivery 불일치)이고, 이걸 리랭커 실패와 섞으면 진단이 틀린다.

4-4. ★책상 위 권고가 실측에 뒤집혔다 — 남길 가치가 있는 기록

2026-08-02 SOTA 조사(코덱스 합의)는 12GB 예산에 맞춰 Qwen3-Reranker-0.6B 를 권고했고 "4B 급은 근거 없이 올리지 않는다" 고 적었다. 그 판단은 옳은 절차였다 — 크기로 품질을 주장하면 안 된다.

그런데 2026-08-04 실측에서 0.6B 는 Hit@1 71.02% · 대체표현 33.67% 로 4B(84.71% · 73.47%)에 크게 밀렸고, 처리량마저 더 느렸다(7.79 vs 11.36 pair/s).

→ 결론을 바꿨다. 다만 4B 는 12GB 전부 상주 예산에 안 들어간다(\$6). 그래서 오프라인 release 로만 쓰고 실시간은 꺼 둔다.

RAG_RERANK_ENABLED=false	# ★기본 OFF
RERANKER_PROVIDER=cross_encoder	
RERANKER_MODEL=Qwen/Qwen3-Reranker-4B	
RERANKER_FALLBACK_MODEL=BAAI/bge-reranker-v2-m3	
RERANKER_DTYPE=float16	
RERANKER_BATCH_SIZE=1	
RERANKER_MAX_LENGTH=768	
RERANKER_OVER_FETCH=20	
RERANKER_TRUST_REMOTE_CODE=false	

★"선정·검증된 리랭커"와 "항상 켜진 실시간 리랭커"는 다른 말이다. 발표에서 섞지 않는다.

4-5. 무효 결과도 기록한다 — Querit/Querit-4B

- 로드 로그: score.weight 가 체크포인트에서 초기화되지 않고 무작위 초기화됐다는 경고
- 8,273개 점수가 전부 0.76025390625 — dense 순서를 한 건도 바꾸지 못함
- 판정: 모델 품질이 낮다고 결론 내리지 않고 checkpoint/scoring-adapter incompatibility 로 분류

★상수 점수를 "성능 나쁨"으로 적었으면 그 모델에 대한 거짓 기록이 남았을 것이다. 그래서 점수 게이트(membership · finite · non-constant)를 평가 코드에 넣었다.

4-6. 고정 revision

모델	revision
Qwen/Qwen3-Reranker-4B	22e683669bc0f0bd69640a1354a6d0aebcfeede5
BAAI/bge-reranker-v2-m3	953dc6f6f85a1b2dbfca4c34a2796e7dde08d41e
Alibaba-NLP/gte-multilingual-reranker-base	8215cf04918ba6f7b6a62bb44238ce2953d8831c
Qwen/Qwen3-Reranker-0.6B	e61197ed45024b0ed8a2d74b80b4d909f1255473
jinaai/jina-reranker-v2-base-multilingual	9cfeff2df7d40d1b78e75e5e9cebec92a99813c9
dragonkue/snowflake-arctic-embed-l-v2.0-ko	(accepted_extraction.json 의 embed_profile.revision — ★비어 있다. 고정 필요)

5. OCR / VLM — ★답변 LLM 이 아니다

자기부담금처럼 행·열 관계가 의미를 결정하는 표만 선별해 OCR 에 보낸다. 전체 문서를 무조건 OCR 하지 않는다.

표 후보 탐지 → 어려운 페이지만 선별 → OCR·유형별 추출 → ★사람 승인 → 인덱스 편입

↳ 미승인은 shadow 로 보존·차단

실적 (S7.1)

	값
사람 검수 패턴	29
승인(approve)	24패턴 · 850 facts
수정 필요(fix)	5패턴 · 216 facts → 격리
승인 facts → 청크	75 (원문 표기 차이 보존)
승인 facts → occurrence	850 · 179문서
미승인 shadow facts	8,622 (B8 8,586 + F4 36)
미승인의 DB occurrence	0 ← 차단 확인

★OCR 산출물을 판정 근거로 쓰려면 사람 승인이 필요하다. 승인 전에는 파일로 보존만 하고 DB-serving-citation 어디에도 넣지 않는다.

6. ★VRAM 예산 — RTX 4070 SUPER 12GB 기준

GPU 상자: Ryzen 5 8600G 12스레드 · RTX 4070 SUPER 12GB .

6-1. 전부 상주 조합 (권고)

모델	가중치	실행 증
PaddleOCR-VL-1.6 BF16	1.79 GiB	2.3~2.8
korean PP-OCrv5 mobile rec	0.014	0.05~0.1
multilingual-e5-large BF16	~1.05	1.25~1.45
Qwen3-Reranker-0.6B BF16	1.11	1.3~1.55
Gemma-4-E4B Q4 (text only)	4.80	5.4~5.8
합	~8.8 GiB	피크 10.5~11.6 GiB

조건: 생성 4K · 리랭크 1K · 배치 1~4 · 동시 요청 1 · **Gemma 멀티모달 projector 미로드.**

★초판이 "Gemma Q4 ~4.5GB" 라고 적었는데 부족한 수치였다. 공식 Q4 GGUF 는 텍스트 가중치만 5.15GB, 멀티모달 projector 가 추가 992MB 다. 생성에는 projector 를 로드하지 않아야 한다.

6-2. 그래서 4B 리랭커는 왜 실시간이 아닌가

위 표는 리랭커가 0.6B 일 때의 예산이다. 실측에서 이긴 4B 로 바꾸면 전부 상주가 깨진다. → 4B 는 별도 GPU(RTX 4000 Ada)에서 오프라인 배치로 돌려 release 를 만들고, 실시간 경로는 RAG_RERANK_ENABLED=false 로 둔다. GPU serving·동시성·OOM 시험 뒤에 켜다.

6-3. 하드웨어를 늘리면?

	열리는 것	실익
16GB	Qwen3.5-4B BF16 전부 상주가 간신히(피크 14.5~15.8 GiB)	작다. 로딩 지연이 줄 뿐 — 정확도·근거성·기권 정책은 개선되지 않는다
32GB	Gemma BF16 · 4B 리랭커 동시 상주 · 12B Q4	제한적. 4B 리랭커가 일반 벤치에서 앞서지만 재색인·임계값 재조정·지연·테스트 범위는 확실히 증가

★하드웨어를 늘려도 이 제품의 실패 모드(잘못된 보장 판정)는 줄지 않는다.

6-4. ★RunPod 은 연산 확장 자원이 아니다

올려도 되는 것	절대 안 되는 것
공개 모델 가중치·토큰나이저	실제 진료비 내역서·처방전
애플리케이션 코드·양자화 스크립트	OCR 결과 · 문서 청크 · 프롬프트 · 검색 결과 · 생성 로그
완전 합성 문서	의료문서로 만든 임베딩·벡터DB·캐시·LoRA 체크포인트
공개 벤치마크	약관 원문·스캔·OCR 텍스트

★암호화 전송·저장을 해도 GPU 메모리에서는 평문으로 처리된다. → RunPod 16/32GB 는 공개·합성 자료 기반 개발·비교·부하시험 전용이다.

7. 추론 파라미터 (현재 값)

슬롯	파라미터	값	출처
생성	n_ctx	1024	scripts/local_model_server.py:62
생성	quantization	Q4_0 (QAT)	model_registry.yaml
생성	요청 타임아웃	120초 / health 3초	.env.example
임베딩	dim / max_seq_length	1024 / 8192	config/accepted_extraction.json
임베딩	chunk_budget / overlap	448 / 80	같은 곳
검색	HNSW 연산자	vector_l2_ops	pgvector_clause_index.py:540
리랭커	dtype / batch / max_length	fp16 / 1 / 768	.env.example
리랭커	over-fetch	top20	같은 곳

★ temperature · top_p · max_tokens 는 서버가 요청에서 그대로 전달한다 (local_model_server.py:106) — 코드에 고정값을 박지 않았다.

8. 성능 요약 (측정일·범위를 붙여서)

지표	값	범위	측정일
retrievable Hit@1	84.71%	314문항 · Qwen3-4B 리랭크 후	2026-08-04
retrievable MRR@10	0.9101	같은	2026-08-04
전체 Hit@1	63.79%	417문항 · 종단	2026-08-04
기존 gold rank 회귀	0건	S7 → S7.1	2026-08-04
pgvector top20 p50 / p95	323ms / 364ms	warm · 승인 OCR 벡터	2026-08-04
리랭크 처리량	11.689 pair/s	RTX 4000 Ada · 8,285 pair	2026-08-04

9. ★이 문서가 주장하지 않는 것

- 1. "Arctic-ko 가 최고다" — 상위 그룹은 신뢰구간이 겹친다. 예비 후보 축소까지다(\$3-4).
- 2. "Gemma 로 답변 품질이 좋다" — 라이브 품질 승인이 없다. verified_at: null 이다(\$2-5).
- 3. "리랭커가 켜져 있다" — 기본 OFF 다. 오프라인 release 만 있다(\$4-4).
- 4. "OCR facts 로 정확도가 올랐다" — 측정한 것은 기존 검색 비회귀다. 신규 facts 전용 holdout 은 없다.
- 5. "12GB 예산표가 실측이다" — 공개 스펙 기반 추정이다. memory_peak_mb 는 아직 null 이다.

참조

- 레지스트리: model_registry.yaml · app/core/model_registry.py
- 게이트웨이: app/adapters/llm_gateway.py · app/core/llm_clients.py