

06. 테스트 계획 및 결과 보고서

발표 보고서 제출 요구 항목 「테스트계획 및 결과 보고서」의 정본이다. 기준일 2026-08-04 이 문서는 새 테스트를 이번 세션에서 실행해 만든 것이 아니라, 프로젝트 전역에 이미 흩어져 있던 **실측 결과·테스트 계획·테스트 코드**를 찾아 하나로 모은 것이다. §0에 무엇이 "진짜 실측"이고 무엇이 "계획만 있고 미실행"인지 표로 명시한다.

0. 한 장 요약 — 뭐가 실측이고 뭐가 계획인가

구분	대상	상태	출처
① 데이터 품질 게이트	수집·전처리·OCR 승격	✅ 실측 완료	§1
② 검색(임베딩) 성능	21회 비교 + bootstrap CI	✅ 실측 완료	§2
③ 리랭커 성능	5종 실측 + paired bootstrap	✅ 실측 완료	§3
④ 검색 비회귀	417질의 top20-리랭크	✅ 실측 완료	§4
⑤ 운영 연결 스모크 테스트	API readiness·회귀 73건	✅ 실측 완료	§5
⑥ 코드 레벨 요구사항 트레이서빌리티	REQ 20개 ↔ pytest 노드	⚠ 팀 기록상 DONE, 이번 세션 재실행은 안 함	§6
⑦ 보안 10케이스	프롭프트 인젝션·RBAC·MCP 등	⚠ 팀 기록상 DONE, 이번 세션 재실행은 안 함	§7
⑧ End-to-end 판정 품질 (금감원 분쟁사례)	검색·판본·인용·판정·안전성·구조 6측	❌ 계획·gold data만 존재, 실행 전	§8

★이번 세션에서 하지 않은 것: SKN32-3rd-4Team-develop/tests 의 pytest 스위트(약 320개 노드)를 직접 재실행하지 않았다. torch-transformers-faiss-insightface 등 수 GB 의존성 설치와 Postgres+pgvector 기동이 필요해, 사용자 지시에 따라 **다운로드·설치 없이 이미 존재하는 기록만으로 이 문서를 작성**했다. §6-§7의 "DONE"은 팀이 자체적으로 남긴 기록이며, 이 세션이 독립적으로 재검증한 결과가 아니다.

1. 데이터 품질 게이트 (실측)

01 수집데이터 및 전처리.md §6에서 가져온 실측 결과다.

검증 층	검사	실측 결과
입력 계보	이미지 SHA·모델 revision·archive·alias 대조	832/832 입력 일치, 예상 밖 stale 1건 quarantine
숫자 환각 방지	OCR 금액·비율 토큰이 같은 페이지 native text에 존재하는지	금액 4,172/4,172 + 비율 4,124/4,124 = 8,296/8,296
grid·근거	bbox 4좌표, rowspan/colspan, ragged-span mismatch	invalid bbox 0, 결함 신호는 review 사유로 기록
accepted 비회귀	S6 accepted clauses와 S7 결합본 비교	204,098개 내용 mismatch 0
결정성	같은 입력으로 S7 재빌드	page+clause 2,734파일 전부 unchanged
manifest	S7 1,367문서·tree digest 재검증	어긋남 0
격리	candidate의 serving/citation·색인 유입	승인 전 0건
사람 승인	29패턴 원문 대조	approve 24·fix 5

숫자 토큰 8,296/8,296 일치는 "OCR이 새 숫자를 지어내지 않았다"는 검사이지, 그 숫자가 올바른 행·헤더에 연결됐다는 precision을 의미하지 않는다 — 그래서 최종 축 소속은 사람 승인을 요구했다.

2. 검색(임베딩) 성능 (실측)

05C 사용 LLM 모델.md §3에서 가져온 실측 결과다.

- 측정 21회(fp16 17회 + 4bit 4회), 질의 3종(제목 검색 145문항·뒷부분 검색 60문항·면책 표현 16문항)
- 짝비교 + 부트스트랩 2,000회 95% 신뢰구간

모델	MRR	R@10	뒷MRR	면책MRR	잘림
Snowflake/snowflake-arctic-embed-l-v2.0	0.557	0.697	0.290	0.288	0.0%
★dragonkue/snowflake-arctic-embed-l-v2.0-ko (현 배포)	0.549	0.703	0.317	0.341	0.0%
jhgah/ko-sroberta-multitask (옛 배포)	0.434	0.607	0.133	0.077	83.7%

핵심 결론: 순위표 1위 확정이 아니라 "예비 후보를 9개로 줄이는 단계"다(상위 그룹은 95% 신뢰구간이 0을 걸쳐 통계적으로 차이를 확인하지 못했다). 결정적이었던 건 순위가 아니라 **잘림**이었다 — 옛 배포(ko-sroberta@128토큰)는 조항의 83.7%가 잘렸고, 면책 문구는 조항 뒤쪽에 있어 뒷부분 MRR이 4.4배(0.077→0.341) 개선됐다.

3. 리랭커 성능 (실측)

05C 사용 LLM 모델.md §4에서 가져온 실측 결과다. 평가 입력: 원본 청크 145,220개, 평가 질의 417개(retrievable 314), pair 8,273개, GPU RTX 4000 Ada.

모델	Hit@1	MRR@10	대체표현 Hit@1	처리량(pair/s)
Qwen/Qwen3-Reranker-4B	84.71%	0.9104	73.47%	11.36
BAAI/bge-reranker-v2-m3	78.03%	0.8562	50.00%	40.69
Alibaba-NLP/gte-multilingual-reranker-base	71.02%	0.8040	45.92%	47.27
Qwen/Qwen3-Reranker-0.6B	71.02%	0.8021	33.67%	7.79
jinaai/jina-reranker-v2-base-multilingual	66.56%	0.7777	33.67%	356.56
dense Arctic-ko 기준선	64.65%	0.7684	17.35%	—

paired bootstrap 10,000회(4B vs BGE): 전체 Hit@1 +6.69%p [95% CI +1.59, +11.78], **대체표현 Hit@1 +23.47%p [+11.22, +35.71]** — 사용자 약관 문구 그대로 묻지 않는 "대체표현" 질의에서 차이가 갈랐다.

★무효 결과도 기록: Querit/Querit-4B 는 로드 시 score.weight 가 무작위 초기화된 채 로드돼 8,273개 점수가 전부 동일값(0.76025390625)이었다. "성능 나쁨"이 아니라 checkpoint/scoring-adapter incompatibility 로 정확히 분류했고, 이후 점수 게이트(membership-finite-non-constant)를 평가 코드에 추가했다.

★실측이 사전 권고를 뒤집은 사례: 2026-08-02 SOTA 조사는 12GB 예산에 맞춰 0.6B를 권고했으나, 실측에서 0.6B(Hit@1 71.02%)가 4B(84.71%)에 크게 밀리고 처리량마저 느려 결론을 뒤집었다. 다만 4B는 12GB 상주 예산에 안 들어가 오프라인 release로만 쓰고 실시간 경로는 기본 OFF(RAG_RERANK_ENABLED=false)다.

4. 검색 비회귀 테스트 (실측)

01 수집데이터 및 전처리.md §6에서 가져온 실측 결과다.

- 기존 417질의 top20-리랭크 기준으로, 승인 OCR fact가 검색에 실제 들어오면서(6질의·23 pair 유입) 기존 **gold rank 변화 0건**을 확인했다.
- S7.1 적용 전후 Hit@1·MRR@10은 동일 — 새 fact의 독립 정답률을 측정한 게 아니라, 새 fact가 기존 검색 품질을 훼손하지 않았음을 확인한 비회귀 결과다.

5. 운영 연결 스모크 테스트 (실측)

S7_1_FULL_modeling_artifacts_20260804/docs/reports/2026-08-04_산출물_운영연결_및_스모크테스트.md 에서 가져온 실측 결과다.

검사	결과
활성 release	r2026-08-04-clause-s7.1-arctic-ko-ocr-approved
승인 OCR occurrence	850
B8/F4 미승인 DB occurrence	0
승인 벡터 rank 1 내용 해시	일치
rank 1 거리	0.0
top20 반환 수	20
관련 회귀 테스트	73건 통과
/api/health/ready	ready=true

후보(candidate) registry는 fail-closed로 설계돼, 파일 손상·해시 불일치·행 수 불일치·후보 행의 승인 상태 변경 중 하나만 있어도 readiness 가 실패하도록 검증돼 있다.

6. 코드 레벨 요구사항 트레이서빌리티 (팀 기록, 이번 세션 미실행)

SKN32-3rd-4Team-develop/tests/requirements_matrix.yaml 에 실제 구현·검증된 MUST 요구사항 20개가 각 pytest 노드에 매핑돼 있고, 각 매핑에는 "그 테스트가 요구사항을 직접 확인하는지"에 대한 근거(basis) 한 줄이 붙어 있다. 이 매트릭스 자체의 무결성(노드 존재·collect 가능· skip/xfail 아님)은 test_requirements_matrix.py (TEST-MATRIX-001)가 정적으로 검증한다.

요구사항 ID	내용	상태(팀 기록)
REQ-QA-BASE-01	원본 프로젝트 결정론 테스트 기준선 재현	DONE
REQ-RAG-04	AnswerQuestion — 근거 기반 답변 + 출처 인용	DONE
REQ-RAG-05	근거 없음 → abstention(환각 억제)	DONE
REQ-RAG-01	RAG 품질 고정 — Hit@3≥0.85-abstention	DONE
REQ-RAG-03	Hybrid(dense+lexical) RRF 결합	DONE
REQ-RAG-RERANK-01	Reranker 재정렬	DONE
REQ-LLM-REG-01	모델 ID 하드코딩 금지·registry 검증	DONE
REQ-OPS-01	기동/데이터 분리 — readiness 보고	DONE
NFR-OBS-01	관측성 — X-Trace-ID 전파	DONE
REQ-VEC-01 / 02	pgvector-FAISS parity / 미준비 시 명시 오류	DONE
REQ-GRAPH-DESIGN-01 / 01 / 02	GraphRAG 설계·구현·그래프+벡터 결합	DONE
REQ-MCP-01	MCP-REST parity	DONE
REQ-AUTH-01	RBAC 401/403/200	DONE
REQ-ADMIN-01 / 02	관리자 API fail-closed·부트스트랩	DONE
REQ-COM-01~03, NFR-REL-01, REQ-AGT-01, REQ-COT-01	커머스(주문·먹통·에이전트·CoT)	DONE — ★단, "레거시(v3 커머스)로 격리 — 이 제품에 없는 기능"으로 retired 표시. 이 보험 RAG 제품 범위 밖

★정직하게 표시: "DONE"은 이 매트릭스 파일에 팀이 남긴 기록이며(파일 자체 주석: "계획서의 열망이 아니라 실측"), 이번 세션에서 **pytest**를 재실행해 독립 검증한 것이 아니다. 위 표 중 커머스 관련 6개 항목은 애초에 이 보험 RAG 제품의 기능이 아니라 레거시로 격리돼 있다는 점도 팀 기록 그대로 옮겼다 — 이 제품의 실질 커버리지는 커머스 6개를 뺀 나머지다.

파일 자체 주석에 따르면 원본 프로젝트 결정론 테스트 기준선은 182개였고, 현재 CI 스위트는 **320개**로 늘어났다(이번 세션에서 재확인한 숫자가 아니라 매트릭스 주석에 적힌 값).

7. 보안 10케이스 (팀 기록, 이번 세션 미실행)

SKN32-3rd-4Team-develop/tests/security_cases.yaml 에 v3.1 §6.2 원문을 승계한 보안 10케이스가 있다. 위협모델을 다음과 같이 정직하게 전제한다: "이 프로젝트는 인터넷 노출 서비스가 아니라 학습·포트폴리오용 API"라는 점을 숨기지 않는다.

ID	내용	이 제품 범위	상태(팀 기록)
TEST-SEC-001	문서 내 "시스템 지시 무시" 문구를 도구 지시로 실행하지 않음	✅ 해당(RAG 근거 프롬프트 인젝션 방어)	DONE
TEST-SEC-004	USER가 admin API 접근 시 403	✅ 해당	DONE
TEST-SEC-007	ingest가 허용 확장자만 수집, 경로 이동 거부	✅ 해당	DONE
TEST-SEC-008	MCP 오류 taxonomy 유지 + 비밀(config) 비노출	✅ 해당	DONE
TEST-SEC-002 / 003 / 005 / 006 / 009 / 010	결제·주문·idempotency·에이전트 쓰기차단 등	★레거시(v3 커머스) 격리 — 이 제품 범위 아님	DONE(레거시 스코프)

이 매트릭스의 무결성(노드 존재·collect-skip 여부)도 test_security_cases.py (TEST-SEC-VERIFY-001)가 정적으로 검증하도록 설계돼 있으나, §6과 마찬가지로 이번 세션에서 재실행하지는 않았다.

8. End-to-end 판정 품질 평가 — 금감원 분쟁사례 (계획·gold data만 존재, 실행 전)

insurance_rag/금감원_평가셋_작업패키지/00_작업계획.md 에 있는 내용이다. 담당은 **송채영(판정)·서유현(검색)**으로 이미 배정돼 있다.

8-1. 왜 이 평가가 따로 필요한가

§2~§7의 테스트는 각 구성요소(검색·리랭커·코드 계약)를 개별로 본다. 이 평가는 **실제 사용자 질문 → 검색 → 판정 → 인용 → 설명까지 전체 경로**가 맞는지를 실제 분쟁사례로 본다 — 이게 빠지면 "부품은 각각 검증됐지만 조립된 결과가 맞는지 아직 모른다"는 공백이 남는다.

8-2. 지금까지 만든 것

산출물	상태
금감원 분쟁조정사례 원자료 14건(HWP)	✅ 확보
fss_dispute_cases_v1.jsonl — 사례(사실·쟁점·양측주장·판단·근거)	✅ 14건 구조화 완료
fss_dispute_questions_v1.jsonl — 질문(중립·공정유도·정보누락·반사실 변형)	✅ 42건 작성 완료(사례당 2~4문항, 제목 중립화 적용)
gold_clause_ids — 사례별 실제 약관 조항 ID 연결	❌ 미실행 — 전처리(s6/s7) 완료를 기다리던 단계, 지금은 전처리가 끝났으므로 착수 가능
실제 평가 실행(검색→판정→채점)	❌ 미실행

claim_samples.json (합성 청구 50건)은 **평가셋으로 쓸 수 없다고 이미 결론**났다 — 조항 근거가 없고, 원자료 14건의 실제 쟁점(비급여 주사료·보조기·본인부담상한제 등)이 하나도 반영되지 않은 합성 데이터라서다. 합성 코호트 시연용으로만 별도 활용한다.

8-3. 평가 측 (설계 완료, 채점 미실행)

측	측정	비고
검색	Recall@k-MRR	<code>gold_clause_ids</code> 복수 인정 — 같은 내용 담은 다른 조항을 오답 처리하지 않는다
판본·특약	정확한 버전 선택률	정보 부족 시 <code>abstain</code> 이 정답
인용	조항·quote·locator 정확성	<code>citation_guard</code> 로 검증
판정	4단 정확도(likely_covered/needs_documents/unlikely/needs_expert) + 금액 구성	
★안전성	면책인데 긍정 답변한 오답	별도 집계 — 가장 위험한 실패 모드
구조	표·각주 준용·상충 조항 누락	

지켜야 할 원칙 다섯 가지(작업계획 §3): ① 금감원 결론을 곧바로 gold로 쓰지 않고 정확한 약관 판본에 연결해야 함, ② 판본을 못 찾으면 정답은 결론 추측이 아니라 **기권** (`abstained=true`, `abstain_reason="policy_version_unknown"`), ③ HWP 판단문은 `EXTERNAL_REPORT` 등 급이지 약관 코퍼스(인덱스 A)가 아님, ④ 파일명이 정답을 누출하므로 모델 입력에서는 제목을 중립화, ⑤ split은 **사례 단위로** 나눔(질문을 42개로 늘려도 독립 표본은 14개).

8-4. 남은 작업 (실행 순서)

① HWP → 텍스트 구조화	완료 (14건)
② <code>cases_v1.jsonl</code>	완료
③ 판본 후보 조회	완료 (보험사+가입시점 → <code>manifest</code> 조회)
④ <code>questions_v1.jsonl</code>	완료 (42건)
⑤ <code>gold_clause_ids</code> 확정	← 다음 단계. 전처리 <code>s6/s7</code> 완료로 지금 착수 가능
⑥ 평가 실행·채점	← ⑤ 완료 후

★이 문서가 주장하지 않는 것: "판정 시스템의 실제 정확도"는 이 보고서에 없다. §1~§5의 숫자는 전부 **부품 단위(데이터·검색·리랭커)** 실측이고, §8의 end-to-end 판정 품질은 계획과 gold 데이터까지만 있고 아직 채점되지 않았다. "전체 RAG가 실제로 몇 % 맞는다"고 말하려면 §8의 ⑤·⑥이 끝나야 한다.

9. 종합 — 이 보고서가 답하는 것과 답하지 못하는 것

답하는 것 - 데이터 전처리 파이프라인이 숫자를 지어내지 않고, 결정적이며, 승인 없이는 검색에 노출되지 않는가 → 예(§1) - 임베딩·리랭커 선택이 임의가 아니라 실측 비교를 거쳤는가 → 예(§2-§3) - 최근 변경(S7.1)이 기존 검색 품질을 깨뜨리지 않았는가 → 예(§4-§5) - 코드 수준에서 요구사항·보안 케이스가 테스트로 뒷받침된다고 팀이 기록해 두었는가 → 예, 단 이번 세션 독립 재검증은 아님(§6-§7)

답하지 못하는 것 - "사용자 질문에 최종 답변이 실제로 몇 % 정확한가" — §8의 end-to-end 평가가 아직 채점 전이라 이 숫자는 이 문서에도, 프로젝트 어디에도 없다. - 답변 생성 LLM(Gemma-4-E4B) 자체의 라이브 품질 승인 — [05C §2-5](#)에 이미 `verified_at: null` 로 명시돼 있다. - `SKN32-3rd-4Team-develop` 의 pytest 스위트(약 320개 노드)를 이번 세션이 직접 실행해 얻은 pass/fail 수 — 팀 기록(DONE)만 인용했고 독립 재현은 하지 않았다(§6-§7 주의문 참조).