

교과목 3 : 초거대언어모델(LLM)

단원 1 : 자연어 데이터 준비

DAY2. 자연어 처리를 위한 워드 임베딩

목 차

1. 워드 임베딩 개요		3
2. 빈도 분석 및 TF-IDF 모델		6
3. 토픽 기반 워드 임베딩		8
4. Word2Vec 활용		10

1. 워드 임베딩 개요

워드 임베딩이란?

1. 자연어(단어)를 컴퓨터가 이해할 수 있는 숫자 벡터로 변환하는 과정
2. 프로그래밍 언어(Python, R)는 텍스트를 직접 처리하지 못하므로 단어를 숫자로 변환하는 작업이 필수적임
3. 텍스트를 의미 있는 단위인 토큰으로 쪼갬 뒤 이를 수치화하는 작업을 의미함
4. 단어의 의미와 뜻을 벡터 공간에 표현하는 기술임
5. 단순히 단어를 나열하는 것이 아니라 여러 축(차원)에 따라 배치하여 분석 가능한 구조를 만듦

워드 임베딩 방법: 원핫 인코딩

1. 원핫 인코딩(One-Hot Encoding)
 - 새로운 단어가 들어올 때마다 그 단어를 좌표 공간의 한 점으로 찍는 방식
2. 각 단어마다 고유한 번호를 매기는 방식임
3. 예
 1. "밥" → [1, 0, 0, 0]
 2. "김치" → [0, 1, 0, 0]
 3. "배추" → [0, 0, 1, 0]
4. 장점
 - 사용 방법이 매우 쉽고 직관적임
5. 한계
 1. 단어가 많아질수록 벡터의 크기가 무한정 늘어나 대용량 데이터 처리에 비효율적임
 2. 단어 간의 거리가 모두 동일하게 취급되어 단어 사이의 의미적 관계를 파악하기 어려움
6. 데이터 규모가 작거나 단순한 지역 코드 등을 숫자로 바꿀 때 주로 사용됨

워드 임베딩 방법: 워드 벡터

1. 워드 벡터(Word Vector)
 - Word2Vec 등으로 불리며, 고정된 차원의 벡터 공간에 단어를 표현함
2. 새로운 단어가 추가되더라도 차원 수가 무한정 늘어나지 않고 고정된 차원 내에서 표현됨
3. 비슷한 의미를 가진 단어들은 벡터 공간상에서 가까운 위치에 자연스럽게 모이게 됨
4. 데이터 규모가 클수록 장점이 확연히 나타나며 대규모 데이터 분석에 강력함
5. 통상적으로 현대의 워드 임베딩은 대부분 이 워드 벡터 방식을 의미함

단어 간 유사도 측정 방법

1. 단어 간 유사도 측정 방법

1) 코사인 유사도(Cosine Similarity)

단어 벡터에 입력된 두 단어의 좌표 간 각도를 이용해 유사도를 측정함

2) 단순한 느낌이 아닌 수학적·기하학적 지표를 통해 유사성을 정량화함

3) 각도에 따른 해석

- ① 각도가 0° 에 가까워 동일한 방향을 가리키면 유사도가 높음(+1)

예시: 좋다-훌륭하다

- ② 각도가 90° 로 수직 관계이면 서로 무관함(0)

예시: 사과-컴퓨터

- ③ 각도가 180° 로 완전히 반대 방향이면 정반대의 의미임(-1)

예시: 좋다-나쁘다

- 4) 이를 통해 동의어, 반의어, 같은 주제의 단어 등을 과학적으로 분류할 수 있음

워드 벡터의 핵심 원리

1. 워드 벡터의 핵심 원리

1) 분산 가설(Distributional Hypothesis)

"비슷한 맥락에서 등장하는 단어들은 비슷한 의미를 가진다"라는 전제에서 출발함

2) 단어를 여러 축(차원)에 따라 좌표로 표현하며, 같은 공간에 위치한 단어들은 비슷한 뉘앙스나 시제를 가졌다고 판단함

3) 벡터 연산

유사성 측정뿐만 아니라 단어 간의 관계를 수학적으로 처리 가능함

4) 예시

왕 - 남자 + 여자 = 여왕

과 같은 추론이 가능함

5) ChatGPT 의 원리

우리말을 벡터 공간으로 변환하여 의미를 숫자로 파악하고 다시 자연스러운 언어로 변환하는 과정을 거침

6) 사람의 언어는 "약간 비슷하다"처럼 추상적이지만 컴퓨터는 "10 점 만점에 몇 점" 식으로 정량적 연산을 수행함

워드 임베딩을 위한 고려사항

1. 워드 임베딩을 위한 고려사항

1) 데이터 품질과 도메인 특화

충분한 양의 고품질 텍스트 데이터가 필요하며 특정 분야(도메인)에 특화된 데이터 사용 시 성능이 향상됨

2) 차원 수 설정

차원이 너무 높으면 과적합과 계산 비용이 증가하고, 너무 낮으면 서로 다른 단어가 같은 좌표에 묶여 의미 왜곡이 발생함

3) 데이터 균형

불균형한 데이터는 편향된 임베딩을 생성할 수 있으므로 전처리 품질이 중요함

4) 검증과 업데이트

복수의 임베딩 방법을 비교 실험해야 하며 신조어나 유행어(예: "개이득")처럼 의미가 변하는 경우 모델을 정기적으로 업데이트해야 함

2. 빈도 분석 및 TF-IDF 모델

빈도 분석의 기초

1. 빈도 분석의 기초

1) 텍스트 데이터를 수치화하기 위해 단어가 등장하는 횟수를 세는 가장 기초적인 방법임

2) 단순 단어 빈도

감상문 등에서 긍정·부정 단어가 몇 번 나왔는지 세어 점수를 매기는 방식임

3) 한계

직설적인 부정 표현이 드문 평가문일 경우 단순 빈도 분석만으로는 모두 긍정적으로 해석될 위험이 있음

4) 상대 빈도

특정 글이 전체 평균보다 얼마나 더 강한 긍정 표현을 쓰는지 비교하여 분석함

5) 이진 빈도(Binary Frequency)

단어의 등장 여부만을 예/아니오로 판단하며 간단하고 빠르지만 의미 파악에는 한계가 있음

6) 특정 분야(예: 인공지능 책)에서 자주 나오는 단어를 통해 해당 글의 주제를 역으로 예상할 수 있음

TF-IDF 모델의 창시자 스토리

1. TF-IDF 모델의 창시자 스토리

1) 1958 년 IBM 의 한스 피터 룬(Hans Peter Luhn)에 의해 제안된 아이디어임

2) 빈도가 높다 = 글을 대표한다?

라는 질문에서 시작되었으며, 빈도가 높다고 해서 무조건 중요한 것은 아니라는 한계를 극복하고자 함

3) 초등학생 일기에서 "나는 오늘"이 가장 많이 나온다고 해서 이것이 일기의 핵심 주제가 될 수 없다는 점에 주목함

4) 현재까지도 거의 모든 검색 엔진의 핵심 기술로 널리 사용되고 있음

TF-IDF 의 원리

1. TF-IDF 의 원리

1) TF(Term Frequency)

단어 빈도

2) IDF(Inverse Document Frequency)

역문서 빈도의 조합임

3) 모든 문서나 챕터에서 공통적으로 너무 자주 등장하는 단어는 문서를 특징짓는 단어가 아닐 가능성이 높다고 판단함

4) 핵심 원리

특정 문서 내에서는 자주 나오지만 전체 문서 집합에서는 희귀하게 등장하는 단어에 높은 가중치를 부여함

5) 예시

IT 문서 모음에서 "컴퓨터"는 빈도가 높지만 중요도는 낮고,

"블록체인"처럼 특정 문서에만 집중된 단어가 핵심 키워드가 됨

6) 흔한 단어에는 점수 벌이익(Penalty)을 주어 중요한 단어를 도드라지게 만들

TF 와 IDF 계산 공식

1. TF 와 IDF 계산 공식

1) 공식

$w_{x,y} = tf_{x,y} \times \log(N / df_x)$ 로 계산되며 로그 함수를 통해 가중치를 조절함

2) 스무딩(Smoothing)

공통 단어일수록 점수가 깎이는 정도를 세밀하게 조정하는 확장 방식을 사용함

3) 장점

해석이 명확하고 직관적이며, 불용어 자동 감소 효과와 문서 유사도 계산에 탁월함

4) 한계

단어의 순서와 문맥 정보를 무시하기 때문에 미묘한 의미 차이를 구별하기 힘들

5) 보완

품사 태깅을 결합하거나 Word2Vec, BERT 같은 문맥 임베딩 기술과 혼합하여 한계를 극복함

3. 토픽 기반 워드 임베딩

워드 임베딩 기술의 발전 과정

1. 워드 임베딩 기술의 발전 과정

1) 1970년대(빈도 기반)

단어가 얼마나 자주 나오는지를 기준으로 배열함

2) 1990년대(LSA)

좌표 평면에 배치하여 비슷한 단어들을 같은 주제로 묶기 시작함

3) 2000년대(LDA)

본격적인 토픽 모델링 기법이 등장하여 비슷한 단어와 문서를 주제별로 연결함

4) 2013년(신경망 임베딩)

Word2Vec, GloVe 등 단어를 벡터로 바꾼 뒤 기준선을 정해 긍정/부정을 판별함

5) 2018년(문맥화된 임베딩)

BERT, GPT 등 스스로 문맥을 이해하고 학습하는 모델이 등장함

6) 2020년~(추론 기반)

추론 능력이 강화되어 요약 및 복잡한 대화가 가능한 모델들이 발전함

토픽 기반 문서 분석의 이해

1. 토픽 기반 문서 분석의 이해

1) 토픽 모델링

Word2Vec 등을 통해 비슷한 위치에 모인 단어와 문서를 같은 주제(Topic)로 묶는 기술임

2) 단순한 긍정·부정 분류를 넘어 영화 내용 등 주제별로 세밀하게 나누어 분석함

3) 사용자 맞춤형 기준을 적용해 기존의 카테고리가 아닌 새로운 분류 체계를 형성할 수 있음

4) 예시

수천 개의 고객 리뷰에서 배송, 품질, 가격, 서비스 등의 주제를 자동으로 추출함

5) 대량의 문서 속에 숨겨진 주제를 발견하는 대표적인 비지도 학습 방법임

LDA 토픽(주제) 모델링 분석 결과

1. LDA 토픽(주제) 모델링 분석 결과

1) LDA 분석 4 단계

문서-주제 분포 확인 → 주제-단어 분포 확인 → 주제 선택 → 단어 생성 순으로 진행됨

2) 분석 결과는 주제별로 어떤 단어들이 어떤 비율과 빈도로 쓰였는지를 수치화된 키워드 묶음으로 보여줌

3) 주제 간 거리 맵(Intertopic Distance)

주제들 간의 유사성을 2D 공간에 표현하여 가까울수록 유사한 내용을 다룸

4) 최적화 과정

축(차원)이 너무 많아 주제가 잘 안 나뉘는 경우 차원 축소를 통해 축의 개수를 조정함

5) 지표를 바탕으로 사람이 직접 결과물을 검토하고 보정하는 판단 과정이 필요함

6) 이러한 번거로움을 해결하기 위해 점차 AI를 통한 자동화 방향으로 기술이 발전하고 있음

4. Word2Vec 활용

Word2Vec 개요

Word2Vec의 학습원리

1. 개념 및 핵심 원리

1. Word2Vec 은 '단어를 벡터로 변화시킨다(Word to Vector)'는 의미로, 단어를 숫자로 변환하여 벡터 공간에 배치하는 밀집 표현기술임
2. '비슷한 문맥에 등장하는 단어들은 비슷한 의미를 가진다'는 분포 가설을 핵심 개념으로 함

2. 학습 방법 및 특징

1. 5~20 개 정도의 단어로 문맥(Window) 크기를 설정하고 샘플 데이터를 생성하여 학습함
2. 단어를 벡터 공간에 배치할 때 긍정/부정, 시점(시간의 순서), 성별 등 다양한 의미적 속성과 방향성을 반영함
3. 단어 간의 수학적 연산을 통한 의미 관계 추론이 가능함
(예: King - Man + Woman = Queen)
4. '환불'과 '취소'를 완전히 다른 단어로 취급하는 기존 원핫인코딩과 달리, 비슷한 맥락에서 사용된 단어들의 의미 속성을 파악하여 유사도를 높게 묶을 수 있음

단어 벡터의 시각화

Word2Vec의 특징 및 강점

1. 시각화의 필요성

1. Word2Vec 학습으로 생성된 단어 벡터는 주로 100~200 차원 이상의 고차원이기 때문에 시각적인 해석이 어려움
2. 고차원의 데이터를 축소하여 그래프로 시각화함으로써, 단어 간의 의미적 군집(집단) 구조와 패턴을 직관적으로 해석하고 이해하기 위함

2. 주요 시각화 기법

1. PCA 기반 시각화
 - 선형 데이터 분석에 쓰이며, 높고 낮음 등 데이터의 단순한 비교 가능성에 초점을 맞출 때 사용함
2. t-SNE 기반 시각화
 - 비선형 데이터 분석에 쓰이며, 문학 장르나 스토리의 긴장도 등 단순 비례로 파악하기 어려운 비선형적 군집 구조를 파악하는 데 적합함

단어의 유사도 측정

단어 유사도 측정의 필요성

1. 유사도 측정 목적 및 지표

1. 단어가 단순히 가깝게 위치하는 것을 넘어, 단어 간의 의미적 관계를 수치로 정량화하여 정확한 관련성을 파악하기 위함
2. 거리 기반 측정법
 - 유클리드 거리나 맨해튼 거리 등을 사용하여 단어 간의 거리를 측정함
3. 코사인 유사도 측정법
 - 유사도가 0에 가까울수록 관련성이 없으며, 0.7 이상이면 높은 유사성을 가진 것으로 판단함

2. 실무 활용 사례

1. 고객 문의 자동 배정
 - 고객 문의 텍스트를 벡터화한 후 기존 카테고리와의 코사인 유사도를 계산하여 0.7 이상일 경우 해당 담당자에게 자동으로 배정함
2. 상품 추천 시스템
 - "남성용 운동화 - 남성 + 여성 = 여성 운동화"
 - 또는 "아이폰 - 스마트폰 + 태블릿 = 아이패드"

와 같이 단어의 벡터 연산과 구매 패턴을 조합하여 상품 추천의 정확도를 향상함

3. 검색 엔진 쿼리 확장
 - '빠른', '당일', '신속' 등 같은 벡터 공간의 가까운 위치에 배치된 단어들을 자동으로 확장하여 검색 범위를 넓힘

4. 기계 번역 및 문서 분류

- 문맥에 가장 적합한 단어를 찾아 번역하거나, 공통 관심사를 가진 키워드 패턴을 발견하여 문서를 자동 분류함