

교과목 3 : 초거대언어모델(LLM)

단원 2 : 자연어 딥러닝

DAY2. 자연어 처리를 위한 텍스트 분류

목 차

1. 텍스트 분류란?		3
2. 텍스트 분류의 종류		5
3. 텍스트 분류 딥러닝 모델		11
4. 최신 텍스트 분류 기술		14

1. 텍스트 분류(Text Classification)란?

텍스트 분류(Text Classification)는 컴퓨터가 문장이나 문서의 내용을 분석하여 미리 정해진 범주 (Class) 중 하나 또는 여러 개로 자동 분류하는 자연어 처리(NLP)의 대표적인 기술이다.

예를 들어 이메일을 스팸과 정상 메일로 구분하거나, 영화 리뷰를 긍정과 부정으로 분류하는 것이 대표적인 텍스트 분류 작업이다.

즉,


입력(Input): 텍스트 데이터

출력(Output): 미리 정의된 클래스(Label)

이다.

1. 텍스트 분류 과정

일반적인 텍스트 분류는 다음 순서로 수행된다.



2. 텍스트 분류의 목적

텍스트 분류는 대량의 문서를 사람이 직접 읽지 않고 자동으로 분석하기 위해 사용된다.

대표적인 목적은 다음과 같다.

- 문서 자동 분류
- 감성 분석
- 스팸 메일 탐지
- 뉴스 분류
- 고객 의견 분석
- 상품 리뷰 분석
- 의료 문서 분류
- 법률 문서 분류
- SNS 게시물 분석
- 챗봇 의도(Intent) 분류

3. 텍스트 분류 예시

예시 1

입력

이 스마트폰은 성능이 뛰어나고 사용하기 편리하다.

출력

긍정

예시 2

입력

지금 회원가입하면 최신 노트북을 무료로 드립니다.

출력

스팸

2. 텍스트 분류의 종류

1. 이진 분류(Binary Classification)

두 개의 클래스만 존재한다.

예)

정상
비정상

또는

승인
거절

2. 다중 분류(Multi-Class Classification)

세 개 이상의 클래스 중 하나를 선택한다.

예)

IT
교육
건강
여행
음식

3. 다중 라벨 분류(Multi-Label Classification)

하나의 문장이 여러 개의 클래스를 동시에 가진다.

예)

문장

인공지능을 활용한 의료 영상 분석 기술이 빠르게 발전하고 있다.

출력

인공지능
의료
영상처리

4. 텍스트 분류에서 사용하는 데이터

일반적으로 다음과 같은 형태를 가진다.

문장	라벨
서비스가 매우 만족스러웠다	긍정
제품이 금방 고장났다	부정
지금 클릭하면 경품을 받을 수 있습니다	스팸
프로야구 개막전 결과	스포츠

5. 텍스트 전처리

텍스트는 바로 사용할 수 없으므로 여러 단계의 전처리를 수행한다.

예)

원문
오늘 새로 출시된 노트북의 성능이 정말 뛰어나다!!
↓
소문자 변환(영문인 경우)
↓
특수문자 제거
↓
형태소 분석
↓
불용어 제거
↓
토큰 생성
↓
벡터화

1). 형태소 분석

문장을 의미 있는 최소 단위로 분리한다.

예)

학생들이 열심히 공부하고 있다.

↓

학생

열심히

공부

하다

한국어에서는 조사와 어미가 많기 때문에 형태소 분석이 매우 중요하다.

대표적인 형태소 분석기

- KoNLPy
- Mecab
- Okt
- Komoran
- Kkma
- Hannanum

2). 불용어 제거

의미가 거의 없는 단어를 제거한다.

예)

학생들이 열심히 공부를 하고 있다.

↓

제거 후

학생

열심히

공부

3). 토큰화(Tokenization)

문장을 단어 단위로 분리한다.

예)

서울의 야경은 아름답고 화려하다.
↓
서울
야경
아름답다
화려하다

4). 정수 인코딩

단어를 숫자로 변환한다.

예)

서울 → 1
야경 → 2
아름답다 → 3
화려하다 → 4

문장

서울 야경 아름답다
↓
1 2 3

5). 패딩(Padding)

문장의 길이를 동일하게 만든다.

예)

[5 8]
↓
[5 8 0 0]
[2 4 7 9]
↓
[2 4 7 9]

6). 벡터화(Vectorization)

컴퓨터는 문자를 이해하지 못하므로 숫자로 변환해야 한다.

(1) BOW (Bag of Words)

단어의 출현 횟수를 이용한다.

예)

문장

커피 맛 최고 커피 향

벡터

커피	맛	최고	향
2	1	1	1

(2) TF-IDF

자주 등장하지만 여러 문서에 공통적으로 나타나는 단어의 중요도는 낮추고, 특정 문서에서만 자주 등장하는 단어의 중요도는 높인다.

장점

- 중요한 단어 강조
- 문서 분류 성능 향상

(3) Word2Vec

단어 의미를 벡터 공간에 표현한다.

예)

자동차
버스
기차
오토바이

의미가 가까우면 벡터도 가깝다.

(4) FastText

Word2Vec를 개선한 모델이다.

장점

- 새로운 단어 처리 가능
- 한국어 처리에 비교적 유리

(5) GloVe

단어의 전역적인 통계 정보를 반영하여 의미를 표현한다.

(6) BERT Embedding

문맥(Context)을 고려하는 임베딩이다.

예)

은행에서 예금을 찾았다. 강가에 있는 은행나무가 아름답다.

같은 "은행"이라는 단어가 포함되어 있지만, 첫 번째 문장에서는 금융기관을 의미하고 두 번째 문장에서는 나무를 의미하므로 문맥에 따라 서로 다른 의미를 벡터로 표현할 수 있다.

3. 텍스트 분류 딥러닝 모델

1. 사용되는 머신러닝 알고리즘

전통적인 머신러닝에서는 다음과 같은 알고리즘을 많이 사용한다.

- Naive Bayes
- Logistic Regression
- Decision Tree
- Random Forest
- Support Vector Machine (SVM)
- XGBoost
- LightGBM

특징은 비교적 적은 데이터에서도 좋은 성능을 보이며, BOW나 TF-IDF와 함께 많이 사용된다.


2. 사용되는 딥러닝 모델

텍스트의 순서와 문맥을 학습하기 위해 다양한 신경망 모델이 사용된다.

- RNN
- LSTM
- GRU
- CNN
- Transformer
- BERT
- GPT

2. 모델 학습

학습 데이터는 일반적으로 다음과 같이 구성된다.



3. 성능 평가

텍스트 분류 모델은 다음과 같은 평가 지표를 사용한다.

평가 지표	설명
Accuracy	전체 예측 중 맞춘 비율
Precision	특정 클래스로 예측한 것 중 실제 해당 클래스인 비율
Recall	실제 해당 클래스를 얼마나 많이 찾아냈는지
F1-Score	Precision과 Recall의 조화평균
Confusion Matrix	예측 결과를 표 형태로 분석
ROC-AUC	분류 모델의 전반적인 성능 평가

4. 실제 활용 분야

분야	활용 예시
전자상거래	상품 리뷰 분류
금융	금융 문서 자동 분류
의료	진료 기록 분석
법률	계약서 자동 분류
교육	학습 자료 자동 분류
SNS	게시글 감성 분석
고객센터	문의 유형 자동 분류
이메일	스팸 메일 탐지
언론	뉴스 기사 자동 분류

5. 텍스트 분류의 장점과 한계

구분	내용
장점	대량의 문서를 빠르게 자동 분류할 수 있으며, 검색·추천·분석 시스템과 쉽게 연계할 수 있다.
한계	학습 데이터의 품질에 크게 영향을 받고, 신조어·은어·오타자 및 문맥 이해가 어려운 경우 성능이 저하될 수 있다. 데이터 불균형이 심하면 특정 클래스에 편향될 가능성 있다.

4. 최신 텍스트 분류 기술

최근 자연어 처리(NLP) 분야의 텍스트 분류 기술은 단순히 단어의 출현 빈도(Bag of Words)나 TF-IDF 를 이용하여 문서를 분류하는 방식에서 벗어나, 대규모 텍스트 데이터를 사전에 학습한 **사전학습 언어모델(Pre-trained Language Model, PLM)**과 **생성형 대규모 언어모델(Large Language Model, LLM)**을 활용하는 방향으로 빠르게 발전하고 있다. 이러한 모델들은 단어 하나의 의미뿐만 아니라 문장의 전체 문맥(Context), 문장 간의 관계, 사용자의 의도까지 이해할 수 있기 때문에 기존 방법보다 훨씬 높은 분류 정확도를 제공한다.

1. BERT 계열 기반 텍스트 분류

BERT(Bidirectional Encoder Representations from Transformers)는 Transformer 의 Encoder 구조를 기반으로 개발된 사전학습 언어모델이다. 기존의 Word2Vec 이나 FastText 가 단어 하나의 의미만 표현하는 것과 달리, 문장의 앞과 뒤 문맥을 동시에 고려하는 양방향(Bidirectional) 학습 방식을 사용한다.

예를 들어 다음 두 문장을 살펴보면,

학생이 은행에 가서 통장을 만들었다.
공원에는 오래된 은행나무가 많다.

Word2Vec 에서는 "은행"이라는 단어가 항상 하나의 벡터로 표현되지만, BERT 는 첫 번째 문장의 "은행"은 금융기관으로, 두 번째 문장의 "은행"은 나무의 한 종류로 구분하여 서로 다른 의미의 벡터를 생성한다. 이처럼 문맥에 따라 단어의 의미를 다르게 이해할 수 있기 때문에 문서 분류, 감성 분석, 질문 분류 등의 작업에서 매우 높은 성능을 보인다.

또한 BERT 는 대량의 일반 텍스트를 이용해 먼저 사전학습(Pre-training)을 수행한 후, 특정 업무에 맞는 데이터만 추가 학습(Fine-tuning)하면 된다. 따라서 적은 양의 학습 데이터만으로도 우수한 분류 성능을 얻을 수 있다.

대표적인 BERT 계열 모델

- BERT
- RoBERTa
- DistilBERT
- ALBERT
- ELECTRA
- DeBERTa

- KoBERT
- KR-BERT
- KoELECTRA

활용 분야

- 감성 분석
- 뉴스 기사 분류
- 이메일 스팸 분류
- 고객 문의 분류
- 법률 문서 분류
- 의료 문서 분류
- 챗봇 의도(Intent) 분류

2. 생성형 대규모 언어모델(LLM)을 이용한 텍스트 분류

최근에는 BERT 와 같은 전용 분류 모델뿐만 아니라 생성형 대규모 언어모델(LLM)을 이용하여 텍스트를 분류하는 방법도 널리 사용되고 있다.

LLM 은 인터넷상의 방대한 문서를 학습하여 언어 자체를 이해하는 능력을 갖추고 있기 때문에 별도의 분류 모델을 새롭게 학습하지 않아도 다양한 분류 작업을 수행할 수 있다.

예를 들어 모델에게 다음과 같이 질문할 수 있다.

다음 문장을 긍정, 부정 중 하나로 분류하십시오.

문장:

"배송이 예상보다 빨라 매우 만족스럽습니다."

모델은

긍정

이라고 바로 답할 수 있다.

또 다른 예시는 다음과 같다.

다음 뉴스를 정치, 경제, 사회, 스포츠 중 하나로 분류하십시오.

이처럼 자연어 명령(Prompt)만으로도 다양한 분류 작업을 수행할 수 있다.

(1) Zero-shot Classification

Zero-shot Classification 은 해당 작업에 대한 추가 학습 없이도 텍스트를 분류하는 방법이다.
즉,

- 분류 데이터를 학습하지 않아도 되고
- 라벨링 데이터가 없어도 된다.

예를 들어,

문장을 다음 항목으로 분류하십시오.

교육
경제
환경
의료

라고 지시하면 모델은 자신의 사전학습 지식을 활용하여 가장 적절한 범주를 선택한다.
장점은 새로운 분야의 데이터에도 빠르게 적용할 수 있다는 점이다.

(2) Few-shot Classification

Few-shot Classification 은 몇 개의 예시만 제공한 후 새로운 문장을 분류하는 방식이다.

예를 들어,

"친절한 상담에 만족했습니다."

→ 긍정

"제품 품질이 좋지 않았습니다."

→ 부정

다음 문장을 분류하십시오.

"고객 응대가 매우 신속했습니다."

모델은 예시를 참고하여

긍정

이라고 분류한다.

Few-shot 방식은 새로운 업무에 빠르게 적응할 수 있어 실무에서 자주 사용된다.

(3) In-context Learning

In-context Learning 은 모델의 가중치를 변경하지 않고, 프롬프트에 포함된 예시만으로 새로운 작업을 수행하는 학습 방식이다.

즉,

모델을 다시 학습시키지 않고

입력
예시 1
예시 2
예시 3
새로운 문장

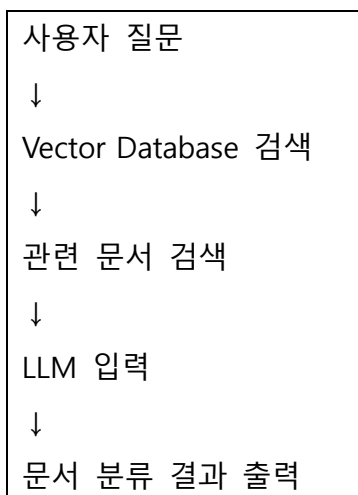
형태의 프롬프트만 제공하면 모델이 패턴을 이해하여 분류를 수행한다.

이 방식은 대규모 모델의 가장 큰 특징 중 하나이며, 빠르게 새로운 업무에 적용할 수 있다는 장점이 있다.

3. 검색 증강 생성(RAG)을 이용한 텍스트 분류

RAG(Retrieval-Augmented Generation)는 검색(Retrieval)과 생성(Generation)을 결합한 기술이다. 기존의 LLM 은 학습 시점 이후의 정보를 알지 못하지만, RAG 는 외부 문서나 데이터베이스에서 필요한 정보를 검색한 후 그 결과를 바탕으로 분류나 답변을 수행한다.

예를 들어 기업의 사내 문서를 분류한다고 가정하면,



의 과정을 거친다.

대표적인 Vector Database 는 다음과 같다.

- Qdrant
- FAISS
- Milvus
- Chroma
- Pinecone
- Weaviate

RAG 를 사용하면 최신 문서나 사내 데이터와 같은 모델이 학습하지 않은 정보도 활용할 수 있어 정확도가 향상된다.


활용 사례

- 사내 문서 자동 분류
- 고객 상담 이력 분류
- 법률 문서 검색 및 분류
- 의료 논문 분류
- 연구 논문 분류
- 이메일 자동 분류


4. 하이브리드(Hybrid) 텍스트 분류 모델

실무에서는 하나의 방법만 사용하는 경우보다 여러 기법을 결합한 하이브리드(Hybrid) 모델을 사용하는 사례가 증가하고 있다.

예를 들어,



또는



와 같은 구조를 사용할 수 있다.

하이브리드 모델은 기존 통계 기반 특징과 딥러닝 기반 의미 정보를 함께 활용하여 성능을 향상시키는 것이 목적이다.


대표적인 조합

- TF-IDF + SVM
- TF-IDF + XGBoost
- BERT + Softmax
- Sentence-BERT + Random Forest
- Sentence-BERT + XGBoost
- Embedding + Vector Search + LLM
- RAG + LLM
- Graph Neural Network + Transformer

5. 최신 실무 동향

최근 기업에서는 단순히 문서를 하나의 카테고리로 분류하는 것을 넘어, 검색, 분류, 요약, 질의응답을 하나의 시스템으로 통합하는 방향으로 발전하고 있다.

대표적인 구조는 다음과 같다.



이러한 구조는 검색 증강 생성(RAG) 기반 문서 이해 시스템으로 발전하고 있으며, 기업의 지식관리(Knowledge Management), 고객지원(Customer Support), 전자문서 관리(EDMS), 의료 정보 분석, 금융 리포트 분석 등 다양한 분야에서 활용되고 있다.

6. 최신 텍스트 분류 기술의 특징 비교

구분	기존 머신러닝	BERT 계열	생성형 LLM	RAG 기반	하이브리드 모델
문맥 이해	거의 불가능	매우 우수	매우 우수	매우 우수	매우 우수
추가학습 필요	필요	미세 조정(Fine-tuning) 필요	경우에 따라 불필요(Zero-shot/Few-shot 가능)	검색데이터 구축 필요	구성에 따라 다름
최신정보 반영	어려움	어려움	제한적	매우 우수	우수
학습데이터 요구량	많음	비교적 적음	매우 적거나 불필요	검색문서 중심	중간
추론 속도	매우 빠름	빠름	상대적으로 느림	검색+추론으로 느림	중간
대표 활용	스팸분류, 감성 분석	문서분류, 감성 분석, 의도 분류	범용분류, 다목적 AI 비서	기업문서 분류, 지식 검색	대규모 실무 AI 시스템

7. 향후 발전 방향

향후 텍스트 분류 기술은 단순히 문서를 하나의 범주로 분류하는 수준을 넘어, 문서의 의미를 종합적으로 이해하고 추론하는 방향으로 발전하고 있다. 특히 생성형 AI 와 검색 기술이 결합되면서, 문서 분류는 검색, 요약, 추천, 질의응답, 정보 추출과 통합된 형태로 구현되는 사례가 증가하고 있다.

또한 멀티모달 AI 의 발전으로 텍스트뿐만 아니라 이미지, 표, 그래프, 음성 등 다양한 형태의 정보를 함께 분석하여 분류하는 기술이 확대되고 있으며, 기업에서는 LLM, RAG, 벡터 데이터베이스, 에이전트(Agent) 기술을 결합한 지능형 문서 처리 시스템을 구축하는 사례가 늘어나고 있다. 이러한 기술은 대규모 문서 관리, 고객 지원 자동화, 연구 자료 분석, 의료 및 금융 분야의 의사결정 지원 등에서 핵심적인 역할을 수행할 것으로 전망된다.